FACULTAD DE INGENIERÍA

CARRERA DE INGENIERÍA DE SISTEMAS COMPUTACIONALES

INFORME DE PROYECTO FINAL

BASE DE DATOS AVANZADAS Y BIG DATA

Solución de Inteligencia de Negocios y Solución Big Data

Doña Gumi: Análisis de recorridos de distribución

DATOS DEL EQUIPO	INFORMACIÓN	
Autores	Araujo Garcia, Piero Shamir Giraldo Alejos, Diego Eugenio Huertas Talavera, Fabiana Janeeth Málaga Anglas Piero Fabrizio	100% de participación 100% de participación 100% de participación 100% de participación
Docente	Chavez Bardales Víctor Isaac	
Curso / NRC	Base de Datos Avanzadas y Big Data / 26049	
Repositorio	https://github.com/FabianaDevPE/PROYECTO-DO-A-GUMI-.git	
Período	2026-2	

Lima- Perú

2026_2

ORIENTACIONES PARA EL PROYECTO Y EL INFORME

Propósito del proyecto: desarrollar, integrar y evaluar una solución de Inteligencia de Negocios y una solución Big Data que respondan a una necesidad empresarial verificable. El informe debe demostrar decisiones de ingeniería, experimentación reproducible y dominio técnico de ambas soluciones.

Alineación referencial con ABET: este formato operacionaliza el Student Outcome 6 de ABET EAC mediante evidencias directas de diseño y ejecución de experimentos, análisis e interpretación de datos y conclusiones sustentadas con juicio de ingeniería.

Entregables obligatorios

N.°	ENTREGABLE	EVIDENCIA MÍNIMA
1	Informe técnico	Documento completo con citas válidas, tablas, figuras y trazabilidad de evidencias.
2	Solución BI functional	Modelo dimensional, ETL/ELT, almacén de datos o data mart, indicadores, análisis OLAP y dashboard.
3	Solución Big Data functional	Ingesta, almacenamiento y procesamiento escalable o distribuido, consultas/análisis y demostración técnica.
4	Paquete experimental	Dataset original y procesado, scripts/notebook, configuraciones, logs, métricas, resultados y visualizaciones.
5	Repositorio versionado	Código, documentación, historial de cambios, etiqueta de versión final y evidencia de aportes individuales.
6	Defensa y mejora	Demostración funcional, respuesta individual, retroalimentación recibida y mejoras implementadas.
7	Uso responsable de IA	Declaración de herramientas, propósito, verificación, autoría intelectual, privacidad y limitaciones.

Convenciones de presentación de evidencias

1. Identifique cada evidencia con un código único (por ejemplo, E-01, E-02) y úselo en el informe, anexos y repositorio.
2. Todo resultado debe indicar dataset, versión del código, configuración, fecha de ejecución y responsable.
3. Los enlaces deben ser accesibles para el docente y conservar una versión congelada del entregable final.
4. No reemplace el análisis técnico por capturas: las capturas complementan, pero no sustituyen, datasets, scripts, métricas, tablas y logs.
5. La evaluación del resultado de experimentación requiere evidencia individual además del producto grupal.

ÍNDICE

Palabras clave **6**
Keywords **7**
CAPÍTULO I: CONTEXTO, PROBLEMA Y OBJETIVOS **8**
1. Contexto, problema y objetivos **8**
1.1. Contexto y necesidad empresarial 8
1.2. Formulación del problema de ingeniería 9
1.2.1. Problema
Dificultad para planificar y analizar los recorridos de distribución de Doña Gumi 9
1.2.2. Causas 9
1.2.3. Consecuencias 10
1.2.4. Necesidad de las soluciones BI y Big Data 10
1.3. Objetivos 10
1.3.1. Objetivo general: 10
1.3.2. Objetivos específicos 11
1.4. Alcance, restricciones y supuestos 11
1.4.1. Alcance 11
1.4.2. Restricciones 12
1.4.3. Supuestos 13
1.5. Stakeholders y criterios de éxito 13
1.5.1. Criterios de éxito del proyecto 14
1.6. Fuentes, gobierno y ética de los datos 15
CAPÍTULO II: ANTECEDENTES Y FUNDAMENTOS **17**
2. Antecedentes y fundamentos **17**
2.1. Antecedentes 17
Antecedente 1 — Dashboard de ventas en una empresa de distribución (BI) 17
Antecedente 2 — Dashboards integrados de desempeño con Power BI (BI) 17
Antecedente 3 — Arquitectura Big Data distribuida para datos de vehículos (Big Data) 18
Antecedente 4 — Big Data aplicado a la optimización de rutas logísticas (Big Data) 18
Antecedente 5 — Benchmark de escalabilidad Hadoop vs. Spark (experimentación Big Data) 19
2.2 Fundamentos de Inteligencia de Negocios 19
2.3 Fundamentos de Big Data 21
2.4 Tecnologías, estándares y trabajos relacionados 23
CAPÍTULO III: DISEÑO DE INGENIERÍA DE LAS SOLUCIONES **26**
3. Diseño de Ingeniería de las soluciones **26**
3.1. Requerimientos funcionales y no funcionales 26
3.1.1. Requerimientos funcionales: 26
3.1.2. Requerimientos no funcionales: 26

3.2. Alternativas y decisiones de arquitectura 27
3.3. Arquitectura integrada y flujo de datos 28
3.4 Diseño de la solución de Inteligencia de Negocios 29
3.5 Diseño de la solución Big Data 36
3.5.1 Justificación y requisitos Big Data 36
3.5.2 Arquitectura y componentes 36
3.5.3 Modelo y ciclo de vida de datos 36
3.5.4 Escalabilidad, resiliencia y operación 36
3.5.5 Resultados 38
3.6 Seguridad, privacidad y riesgos 40
3.7 Plan de despliegue y aceptación 41
CAPÍTULO IV: DISEÑO DEL EXPERIMENTO 43
4.1 Pregunta experimental, objetivo e hipótesis 43
4.2 Escenario y datasets 43
4.3 Variables, métricas y criterios de aceptación 44
4.4 Entorno, herramientas y reproducibilidad 45
4.5 Matriz de escenarios experimentales 46
4.6 Procedimiento reproducible 47
4.7 Riesgos, validez y limitaciones del experimento 47
Riesgos y Amenazas a la Validez: 47
Limitaciones del Experimento: 48
CAPÍTULO V: IMPLEMENTACIÓN Y CONTROL DE EVIDENCIAS 49
5.1 Estructura y versión del repositorio 49
5.2 Implementación de la solución BI 49
1. Modelo Dimensional 49
2. Medidas DAX Creadas en Power BI: 49
5.3 Implementación de la solución Big Data 50
5.4 Calidad, seguridad y pruebas 50
5.5 Registro de retroalimentación y mejoras 51
5.6 Contribuciones individuales 51
5.7 Declaración de uso responsable de inteligencia artificial 52
CAPÍTULO VI: EJECUCIÓN, RESULTADOS Y ANÁLISIS DE DATOS 54
6.1 Validación del dataset original y procesado 54
6.2 Registro de ejecuciones 55
6.3 Tabla consolidada de resultados 57
6.4 Visualizaciones y dashboards 58
1. Tarjetas de Indicadores Clave (KPIs) 58
2. Gráfico de Venta Neta Real por Distrito (Barras Horizontales) 58
3. Comportamiento Temporal — Venta Neta Real por Mes (Gráfico de Líneas) 59
4. Composición de Ventas — Venta Neta Real por Categoría (Gráfico de Dona) 59

5. Desempeño Comercial — Venta Neta Real por Vendedor (Barras Verticales) 59
6. Nivel de Servicio — Cobertura Promedio por Zona (Gráfico de Líneas Inferior) 60
7. Panel de Segmentación Interactiva (Slicers / Filtros) 60
6.5 Análisis e interpretación técnica 60
6.6 Verificación de funcionalidad y completitud 62
CAPÍTULO VII: CONCLUSIONES TÉCNICAS Y RECOMENDACIONES 63
7.1 Matriz objetivo-resultado-conclusión-recomendación 63
7.2 Conclusiones técnicas 65
7.3 Recomendaciones 66
CAPÍTULO VIII: RESPONSABILIDAD ÉTICA Y PROFESIONAL 67
8.1 Tratamiento ético, legal y seguro de los datos 67
8.2 Impactos de las soluciones 67
8.3 Compromiso profesional 68
REFERENCIAS BIBLIOGRÁFICAS 69
ANEXOS Y MANIFIESTO DE EVIDENCIAS 71
Lista de anexos sugeridos 72
1. Manifiesto de Evidencias (E-01 a E-16): 72
2. Anexo A. 72
3. Anexo B. 72
4. Anexo C. 72
5. Anexo D. 72
6. Anexo E. 72
7. Anexo F. 72
8. Anexo G. 72
9. Anexo H. 72
10. Anexo I. 73
11. Anexo D (complemento): 73

RESUMEN

El presente proyecto aborda la dificultad para planificar y analizar los recorridos de distribución de la empresa Doña Gumi. El proceso de distribución se organiza mediante zonas o cuadrantes y requiere considerar información relacionada con clientes, vendedores, unidades, recorridos, productos, pedidos, reservas, despachos y ventas. Asimismo, deben considerarse las características de las unidades y determinadas restricciones municipales que pueden afectar la planificación de los recorridos.

El objetivo del proyecto es desarrollar una solución integrada de Business Intelligence (BI) y Big Data que permita analizar la información asociada al proceso de distribución y generar resultados que apoyen la planificación y evaluación de los recorridos.

Debido a restricciones de confidencialidad, no se utilizará la base de datos real de la empresa. En su lugar, se construirá un dataset simulado basado en la estructura y características del proceso identificadas mediante un contacto vinculado a la organización. Además, se utilizará información pública de los productos de la empresa.

La solución BI integrará y transformará los datos para generar indicadores y visualizaciones relacionadas con ventas, cobertura, zonas, vendedores, unidades y recorridos. La solución Big Data permitirá procesar datasets simulados de mayor volumen para analizar patrones y evaluar rendimiento y escalabilidad. La experimentación comparará diferentes escenarios de procesamiento mediante métricas de calidad, rendimiento y escalabilidad.

Palabras clave

Business Intelligence, Big Data, distribución, recorridos, análisis de datos

ABSTRACT

This project addresses the difficulty of planning and analyzing distribution routes at Doña Gumi. The distribution process is organized into zones or areas and requires information related to customers, salespeople, vehicles, routes, products, orders, reservations, dispatches, and sales. In addition, vehicle characteristics and certain municipal restrictions that may affect route planning must be considered.

The objective of the project is to develop an integrated Business Intelligence (BI) and Big Data solution to analyze information associated with the distribution process and generate results that support the planning and evaluation of distribution routes.

Due to confidentiality restrictions, the company's real database will not be used. Instead, a simulated dataset will be created based on the structure and characteristics of the process identified through a contact linked to the organization. Public information about the company's products will also be used.

The BI solution will integrate and transform the data to generate indicators and visualizations related to sales, customer coverage, zones, salespeople, vehicles, and routes. The Big Data solution will process larger simulated datasets to analyze patterns and evaluate processing performance and scalability. The experimental design will compare different processing scenarios using quality, performance, and scalability metrics.

Keywords

Business Intelligence, Big Data, distribution, routes, data analysis

CAPÍTULO I: CONTEXTO, PROBLEMA Y OBJETIVOS

1. Contexto, problema y objetivos

1.1. Contexto y necesidad empresarial

Doña Gumi desarrolla actividades de comercialización y distribución de productos mediante diferentes canales. Para el presente proyecto se analizará específicamente la planificación y gestión de los recorridos realizados para atender a los clientes.

La distribución se organiza mediante zonas o cuadrantes, a los cuales se asignan unidades y vendedores. La operación contempla dos canales de distribución: el canal territorio, orientado principalmente a bodegueros, y el canal mayorista, orientado a mercados de mayor tamaño en Lima.

El canal territorio cuenta con 19 unidades tipo furgón con una capacidad de 3 toneladas y una carga de productos aproximada de 1250 kg por unidad. Estas unidades se asignan a zonas determinadas y realizan la distribución correspondiente a los clientes de dichas zonas.

El canal mayorista cuenta con 3 unidades con capacidades comprendidas entre 4 y 7 toneladas y atiende mercados de mayor tamaño en Lima. La operación de ambos canales considera las características de las unidades y las restricciones municipales aplicables a determinados distritos.

En el proceso de distribución participan vendedores y personal encargado de la entrega de los pedidos y la recepción del dinero. La actividad comercial inicia mediante una preventa realizada por el vendedor, quien registra el pedido del cliente, incluyendo los productos solicitados, cantidades, bonificaciones y valor total. Posteriormente, la operación se formaliza mediante un documento de venta, como una boleta o factura, y la unidad realiza la entrega correspondiente.

La empresa registra información relacionada con clientes, vendedores, unidades, zonas, recorridos, productos y ventas. Los clientes cuentan con un código y se registra su ubicación, zona y vendedor asociado. Asimismo, los recorridos se organizan por

zonas, se mapean y se registra información sobre los clientes visitados y las ventas generadas. La empresa también dispone de información histórica de estos procesos.

1.2. Formulación del problema de ingeniería

1.2.1. Problema

Dificultad para planificar y analizar los recorridos de distribución de Doña Gumi

El proceso de distribución se desarrolla mediante zonas o cuadrantes a los que se asignan unidades y vendedores. Para realizar los recorridos es necesario considerar diferentes variables de operación, como la ubicación y características de los clientes, el tipo de establecimiento, los horarios de atención, las características de las unidades, la zona asignada, las restricciones municipales y los resultados obtenidos en las ventas.

La empresa registra la información relacionada con clientes, vendedores, unidades, recorridos, productos, pedidos, reservas, despachos y ventas. El proceso comercial inicia cuando el vendedor realiza la toma del pedido del cliente. Una vez generado el pedido, este es reservado para asegurar su disponibilidad y posteriormente pasa al proceso de despacho, mediante el cual se prepara y envía la mercadería correspondiente para su entrega. Esta información permite relacionar los pedidos con los clientes, productos, vendedores, recorridos, unidades y resultados de venta.

1.2.2. Causas

- La planificación de los recorridos requiere considerar múltiples variables de operación y comerciales.
- Los clientes se encuentran distribuidos en diferentes zonas o cuadrantes.
- Las unidades presentan diferentes capacidades y características.
- Existen restricciones municipales que deben considerarse para determinados vehículos y zonas.

- Los establecimientos atendidos presentan diferentes horarios y características comerciales.
- La información de clientes, recorridos, pedidos y ventas debe analizarse de manera integrada para obtener indicadores útiles para la toma de decisiones.

1.2.3. Consecuencias

La dificultad para integrar y analizar la información puede dificultar la comparación del desempeño de los recorridos, la evaluación de la cobertura de clientes, la identificación de zonas con mejores resultados comerciales y el análisis del desempeño de vendedores y unidades. Asimismo, puede limitar el aprovechamiento de la información histórica para apoyar la planificación de los recorridos.

1.2.4. Necesidad de las soluciones BI y Big Data

La solución de **Business Intelligence (BI)** permitirá integrar y analizar la información mediante indicadores, consultas y visualizaciones, facilitando el seguimiento de las ventas, cobertura y desempeño de las diferentes zonas, vendedores, unidades y recorridos.

La solución de **Big Data** permitirá procesar datasets simulados de mayor volumen construidos a partir de la estructura del proceso de distribución, con el propósito de identificar patrones y evaluar el comportamiento, rendimiento y escalabilidad del procesamiento ante diferentes volúmenes de información.

1.3. Objetivos

1.3.1. Objetivo general:

Desarrollar una solución integrada de Business Intelligence y Big Data que permita analizar y evaluar el proceso de distribución de Doña Gumi mediante el procesamiento de información de clientes, zonas, vendedores, unidades, recorridos, productos, pedidos, reservas, despachos y ventas, generando indicadores y

resultados que apoyen la planificación de los recorridos de distribución

- la base de datos construida
- la solución BI funcionando
- la solución Big Data funcionando
- indicadores y resultados obtenidos
- evidencia de los experimentos

1.3.2. Objetivos específicos

1.3.2.1. OE1 - Business Intelligence:

Diseñar e implementar una solución de Business Intelligence que integre información de clientes, zonas, vendedores, unidades, recorridos, productos, pedidos, reservas, despachos y ventas, generando indicadores y visualizaciones para el análisis de la distribución.

1.3.2.2. OE2 - Big Data:

Diseñar e implementar una solución Big Data que permita procesar datasets simulados de mayor volumen para analizar patrones relacionados con clientes, productos, pedidos, recorridos y ventas.

1.3.2.3. OE3 - Experimentación:

Evaluar las soluciones BI y Big Data mediante escenarios experimentales comparables, utilizando métricas de calidad, rendimiento y escalabilidad para determinar el comportamiento de las soluciones frente a diferentes volúmenes de datos.

1.3.2.4. OE4 - Integración de resultados:

Analizar los resultados obtenidos para identificar patrones de cobertura, ventas y desempeño de los recorridos, estableciendo criterios que permitan apoyar la toma de decisiones sobre la distribución.

1.4. Alcance, restricciones y supuestos

1.4.1. Alcance

El presente proyecto se enfocará en el **proceso de distribución de Doña Gumi**, específicamente en el análisis de la información relacionada con la planificación y gestión de los recorridos.

El proyecto considerará las siguientes entidades y procesos:

- distritos y zonas o cuadrantes;
- clientes y tipos de establecimientos;
- vendedores;
- unidades de distribución;
- productos;
- recorridos;
- pedidos;
- reservas;
- despachos;
- ventas.

La solución de **Business Intelligence** comprenderá la integración y análisis de los datos mediante indicadores, consultas y visualizaciones que permitan analizar las ventas, cobertura de clientes y desempeño de zonas, vendedores, unidades y recorridos.

La solución de **Big Data** comprenderá el procesamiento de data sets simulados de mayor volumen para identificar patrones y evaluar el rendimiento y la escalabilidad del procesamiento.

El proyecto se limitará al **análisis y apoyo a la toma de decisiones**, por lo que no incluirá la modificación automática de las rutas reales de distribución ni la implementación directa de decisiones operativas en la empresa.

1.4.2. Restricciones

La principal restricción corresponde a la **confidencialidad de la información empresarial**. Debido a esta condición, no se utilizará la base de datos real de Doña Gumi.

Los datos utilizados para la implementación serán **simulados**, tomando como referencia la estructura del proceso y los tipos de datos identificados mediante la información proporcionada por el contacto de la empresa.

Asimismo, el proyecto considera como restricción las características de las unidades de distribución y las restricciones municipales que deben ser contempladas durante la planificación de los recorridos.

Otra restricción corresponde al alcance académico, al tiempo disponible para el desarrollo del proyecto y a los recursos tecnológicos disponibles para implementar y evaluar las soluciones.

1.4.3. Supuestos

Se asumirá que la estructura del dataset simulado permitirá representar escenarios de operación suficientes para desarrollar las soluciones de Business Intelligence y Big Data.

Asimismo, se asumirá que los resultados obtenidos a partir de los datos simulados serán utilizados únicamente con fines académicos y **no serán interpretados como resultados reales de la operación de Doña Gumi**.

Este apartado responde a lo que solicita el formato: delimitar procesos, datos, usuarios, funcionalidades, restricciones, privacidad y supuestos verificables.

-

1.5. Stakeholders y criterios de éxito

STAKEHOLDER	NECESIDAD / DECISIÓN	CRITERIO DE ÉXITO	EVIDENCIA
Responsable de distribución	Analizar el desempeño de las zonas y recorridos para apoyar la planificación.	La solución permite calcular la cobertura de cada recorrido como **clientes visitados / clientes registrados × 100**, identificando los recorridos que alcanzan aproximadamente el **50 % de cobertura** del cuadrante.	E-07 Dashboard BI
Responsable de logística	Analizar las unidades asignadas a las zonas considerando su capacidad y restricciones municipales.	La solución permite consultar para cada unidad su **capacidad, carga, zona asignada y restricción municipal**, y relacionarla con los recorridos realizados.	Dashboard / reporte
Responsable comercial	Analizar el comportamiento de pedidos, clientes, vendedores y ventas.	La solución permite analizar **ventas y pedidos por cliente, vendedor, producto, zona y recorrido**, identificando además los pedidos que alcanzan el valor mínimo de **S/50**.	E-07 Dashboard BI

1.5.1. Criterios de éxito del proyecto

1.5.1.1. CE1.

La solución BI debe permitir analizar las ventas por distrito, zona, vendedor, unidades, recorrido y producto.

1.5.1.2. CE2.

La solución BI debe permitir analizar la cobertura de clientes por recorrido.

-

1.5.1.3. CE3.

La solución debe permitir identificar los recorridos y zonas con mejores resultados de ventas.

1.5.1.4. CE4.

La solución Big Data debe permitir procesar diferentes volúmenes del dataset simulado y registrar métricas de rendimiento y escalabilidad.

1.5.1.5. CE5.

Las soluciones deben producir resultados trazables y reproducibles a partir del dataset y de las configuraciones utilizadas.

1.6. Fuentes, gobierno y ética de los datos

La información utilizada para definir el proceso de distribución de Doña Gumi se obtuvo mediante un contacto vinculado a la empresa, quien proporcionó información general sobre el funcionamiento del proceso y sobre los tipos de datos que son registrados durante las actividades de distribución, pedidos, despachos y ventas.

Debido a razones de confidencialidad, el equipo no tendrá acceso a la base de datos real de Doña Gumi. Por ello, los datos utilizados para la implementación de las soluciones BI y Big Data serán **simulados**, manteniendo como referencia la estructura, variables y características del proceso real descrito por el contacto.

Asimismo, se utilizará información pública disponible en los canales oficiales de Doña Gumi para complementar los datos relacionados con los productos de la empresa.

Los datos simulados incluirán valores ficticios para clientes, vendedores, unidades, zonas, recorridos, pedidos, reservas,

despachos y ventas. No se utilizarán datos personales reales, documentos de identidad, credenciales, números telefónicos reales ni información comercial confidencial de la empresa.

El equipo mantendrá diferenciadas las fuentes de información utilizadas, distinguiendo entre **información del proceso proporcionada por el contacto, información pública y datos simulados**. Asimismo, se documentará la estructura del dataset, las transformaciones realizadas y las limitaciones derivadas del uso de datos simulados.

El uso de los datos estará limitado a fines académicos y los resultados obtenidos no serán presentados como resultados reales de la operación de Doña Gumi.

CAPÍTULO II: ANTECEDENTES Y FUNDAMENTOS

2. Antecedentes y fundamentos

2.1. Antecedentes

Antecedente 1 — Dashboard de ventas en una empresa de distribución (BI)

Belghith Ep Kallel et al. (2024) abordan la dificultad de las empresas distribuidoras para monitorear y controlar sus indicadores comerciales cuando la información de ventas permanece dispersa y sin visualización integrada. Como los autores señalan, un dashboard es "una herramienta de dirección para la toma de decisiones basada en datos" (traducción propia; Belghith Ep Kallel et al., 2024). Para resolverlo, desarrollaron una solución de Business Intelligence en cuatro fases: recolección de datos del área de ventas, construcción de data marts, modelado de datos importado a Power BI y selección de KPIs relevantes para el sector. Los datos provienen de los procesos de venta reales de una empresa farmacéutica distribuidora en Túnez. Como métricas emplearon indicadores comerciales clave (KPIs) de desempeño de ventas, sin reportar cifras de rendimiento técnico del sistema. Los resultados muestran un dashboard interactivo que permite a los tomadores de decisiones visualizar y comparar el desempeño comercial, facilitando el paso de un almacenamiento tradicional de datos hacia un enfoque más analítico.

Antecedente 2 — Dashboards integrados de desempeño con Power BI (BI)

Gonçalves et al. (2023) parten del problema de la baja adopción de herramientas de BI en pequeñas y medianas empresas y de la dificultad para transformar datos de ventas dispersos en información útil para la toma de decisiones. Los autores destacan que "los dashboards ofrecen una forma sintetizada, agregada e interactiva de visualizar información" (traducción propia; Gonçalves et al., 2023). Aplicaron la metodología de Vercellis (análisis, diseño, planificación e implementación/control) y modelaron un esquema en estrella siguiendo a Kimball, con un proceso ETL para construir un data warehouse. Los datos utilizados corresponden al dataset público Amazing MartE U2 (ventas en Europa, 2011-2014). Las métricas o KPIs implementados incluyeron volumen de

ventas, utilidad, número de pedidos y tasas de retención/pérdida de clientes. Los resultados evidenciaron dashboards interactivos que permiten comparar ventas por país, categoría de producto y modo de envío, facilitando el análisis exploratorio.

Antecedente 3 — Arquitectura Big Data distribuida para datos de vehículos (Big Data)

Alexakis et al. (2022) plantean el problema del creciente volumen y variedad de datos generados por sensores vehiculares (velocidad, aceleración, dirección) y la necesidad de arquitecturas escalables para sistemas de transporte inteligente, dado que "las necesidades de escalabilidad de los sistemas de gestión de flotas y tráfico" (traducción propia; Alexakis et al., 2022) superan los enfoques convencionales. Como método, diseñaron una arquitectura distribuida que integra bases NoSQL (MongoDB), Hadoop y Spark en una plataforma unificada que cubre todo el ciclo de adquisición, almacenamiento y análisis de datos. Los datos utilizados son flujos de datos de sensores embebidos en vehículos y vías. No reportan métricas de rendimiento cuantitativas en el resumen, sino que evalúan la solución en términos de cobertura funcional (adquisición-almacenamiento-análisis-reporte en un solo punto). Los resultados muestran una plataforma capaz de superar las limitaciones de los sistemas heredados frente a datos de alta velocidad y variedad.

Antecedente 4 — Big Data aplicado a la optimización de rutas logísticas (Big Data)

Aubakirova (2024) identifica el problema de la creciente complejidad de las operaciones logísticas y la necesidad de datos precisos para optimizar rutas de entrega e inventario ante el crecimiento del volumen de información. El estudio, según la autora, "optimiza eficazmente las rutas de entrega utilizando un algoritmo de agrupamiento" (traducción propia; Aubakirova, 2024). Como método, desarrolló un programa en Python que aplica un algoritmo de clustering para agrupar y optimizar rutas de reparto, acompañado de un diagrama de las etapas de la estrategia y una tabla comparativa de prácticas de Big Data en distintas

empresas logísticas (funcionalidad, datos, resultados, rubro). Los datos corresponden a información de rutas de distribución y a un relevamiento comparativo de casos de empresas logísticas. Como métricas se evaluó la eficiencia del agrupamiento de rutas y la comparación funcional entre empresas. Los resultados confirman que el uso de machine learning y la optimización del almacenamiento/procesamiento de datos mejora significativamente la eficiencia logística.

Antecedente 5 — Benchmark de escalabilidad Hadoop vs. Spark (experimentación Big Data)

Hebabaze et al. (2024) abordan el problema de determinar qué framework de procesamiento distribuido (Hadoop o Spark) ofrece mejor eficiencia y escalabilidad ante el crecimiento exponencial de los datos. Concluyen que los resultados "resaltan los beneficios del procesamiento en memoria de Spark, demostrando su superioridad sobre Hadoop" (traducción propia; Hebabaze et al., 2024). Como método, realizaron un análisis de rendimiento en entornos virtualizados utilizando la suite de benchmarks HiBench, con cargas de tipo micro-benchmark (Sort, WordCount, TeraSort), búsqueda web (PageRank) y aprendizaje automático (Naive Bayes, K-means). Los datos son conjuntos sintéticos generados por HiBench a distintas escalas. Las métricas empleadas fueron tiempo de ejecución, throughput y uso de recursos. Los resultados muestran que Spark supera a Hadoop en la mayoría de escenarios gracias al procesamiento en memoria, aunque Hadoop resulta competitivo en cargas orientadas a disco con volúmenes muy grandes.

2.2 Fundamentos de Inteligencia de Negocios

La **integración de datos** constituye un componente fundamental de una solución de Business Intelligence, debido a que permite consolidar información procedente de diferentes fuentes y relacionarla bajo una estructura común para facilitar su análisis. En el caso de Doña Gumi, la información asociada a clientes, vendedores, preventas, unidades, recorridos, pedidos, reservas, despachos y ventas debe relacionarse de

manera que permita analizar un mismo proceso desde diferentes perspectivas, como cliente, vendedor, unidad, recorrido y resultado comercial. Kimball et al. (2012) destacan la importancia de contar con una adecuada integración de la información como base para el desarrollo de soluciones de BI. En el presente proyecto, esta integración se realizará sobre un dataset simulado construido a partir de la estructura del proceso descrita por el contacto de la empresa.

Para consolidar esta información se utilizará un proceso **ETL o ELT**, mediante el cual los datos son extraídos de las fuentes correspondientes, transformados de acuerdo con reglas de negocio y posteriormente cargados en un repositorio destinado al análisis. Gonçalves et al. (2023) describen este proceso como una etapa en la que los datos son preparados, transformados y cargados para su utilización en un entorno analítico. Para el proyecto, las transformaciones podrán incluir la identificación de registros duplicados, la estandarización de códigos de zonas y la validación de relaciones entre clientes, vendedores, unidades, recorridos y ventas.

Una vez preparados los datos, se aplicará el **modelado dimensional**, mediante el cual se estructuran los datos en tablas de hechos y dimensiones para facilitar el análisis de la información. Las tablas de hechos contienen las medidas que se desean analizar, mientras que las dimensiones proporcionan el contexto de dichas medidas, como cliente, vendedor, zona, producto, unidad y tiempo. Kimball et al. (2012) plantean el esquema en estrella como un modelo ampliamente utilizado para organizar información analítica. En el proyecto de Doña Gumi, este modelo permitirá consultar las ventas y otros indicadores considerando diferentes dimensiones del proceso de distribución.

Debido a que el proyecto se encuentra delimitado al proceso de distribución, se plantea utilizar un **Data Mart de distribución** como repositorio analítico. Este permitirá concentrar la información necesaria para analizar ventas, cobertura de clientes y recorridos, sin abarcar otras áreas de la organización que se encuentran fuera del alcance del proyecto. Este enfoque también se relaciona con aplicaciones de BI

orientadas a procesos o áreas específicas, como la presentada por Belghith Ep Kallel et al. (2024).

El **análisis OLAP** permitirá explorar la información desde diferentes niveles de detalle y perspectivas. De esta manera, será posible analizar las ventas de una zona y posteriormente desagregarlas por vendedor, unidad, recorrido o producto, así como consultar información desde niveles diarios, semanales o mensuales. En el proyecto, este análisis permitirá comparar el comportamiento de las ventas y la cobertura de clientes según diferentes dimensiones del proceso de distribución.

Finalmente, los **indicadores clave de desempeño (KPI)** y los dashboards permitirán presentar los resultados de manera visual y facilitar su interpretación por parte de los usuarios. En el caso de Doña Gumi, se considerarán indicadores relacionados con las ventas por zona, vendedor y recorrido, la cobertura de clientes, el ticket promedio y la participación de los canales de distribución. Estos indicadores serán utilizados posteriormente en la solución BI para facilitar el análisis de los recorridos y apoyar la toma de decisiones. Los trabajos de Gonçalves et al. (2023) y Belghith Ep Kallel et al. (2024) muestran la utilidad de los dashboards interactivos para analizar indicadores comerciales y facilitar la interpretación de la información.

2.3 Fundamentos de Big Data

Aquí hay que ser honestos con algo que el propio formato del informe advierte: no basta con decir "vamos a usar Spark" para justificar que el problema es de Big Data. Hay que mostrar qué característica concreta del problema de Doña Gumi realmente empuja hacia ese terreno, más allá de lo que ya resuelve una base de datos relacional bien diseñada.

Y en este proyecto esa característica no es tanto el volumen actual de la operación al fin y al cabo, 22 unidades entre ambos canales y su historial de ventas caben perfectamente en una base de datos convencional, sino la necesidad de simular y evaluar cómo se comportaría el proceso si esos datos crecieran mucho más: más zonas, más clientes, más años de historial, más granularidad en cada

recorrido. Ese es justamente el ángulo que persigue el OE2 y el OE3 del proyecto: no procesar datos "grandes" porque sí, sino generar datasets simulados de mayor volumen y ver qué pasa con el rendimiento y la escalabilidad del procesamiento a medida que ese volumen aumenta.

Ahí es donde entra la escalabilidad como argumento real. Alexakis et al. (2022) lo plantean bien cuando trabajan con datos de sensores de flotas vehiculares: el problema no es solo la cantidad de datos que llegan, sino que "las necesidades de escalabilidad de los sistemas de gestión de flotas y tráfico" (traducción propia) obligan a pensar en arquitecturas distribuidas desde el diseño, porque un sistema pensado para un volumen fijo se queda corto apenas la operación crece. Para Doña Gumi el paralelo es directo: si mañana la empresa duplica sus unidades o extiende su cobertura a más distritos, la solución tiene que aguantar ese crecimiento sin rediseñar desde cero, y eso es precisamente lo que se va a poner a prueba en el Capítulo IV con los distintos escenarios experimentales.

Otro argumento tiene que ver con la variedad y la naturaleza distribuida del proceso en sí. La operación de distribución no genera un solo tipo de dato limpio y uniforme: hay pedidos, reservas, despachos, recorridos geolocalizados, restricciones municipales por distrito, características de cada unidad. Aubakirova (2024) muestra un caso parecido en logística, donde justamente aplica clustering para agrupar y optimizar rutas de reparto a partir de datos heterogéneos de distintas empresas del rubro. La lógica es la misma que se busca replicar para las zonas y recorridos de Doña Gumi: cuando los datos ya no son solo "una tabla de ventas" sino un conjunto de fuentes con distinta estructura y frecuencia, procesarlos exige herramientas pensadas para eso.

Y el tercer argumento, quizás el más concreto de los tres, es el que se necesita para poder comparar de forma seria las dos soluciones (BI y Big Data) en el experimento del Capítulo IV. Hebabaze et al. (2024) comparan Hadoop y Spark exactamente bajo esta lógica: no

se trata de asumir que uno es mejor que el otro, sino de medirlo con cargas de trabajo crecientes y ver en qué punto el procesamiento distribuido empieza a marcar diferencia frente al procesamiento convencional. Sus resultados muestran que Spark saca ventaja gracias al procesamiento en memoria, pero que esa ventaja no es automática ni universal, depende del volumen y del tipo de carga. Esa misma idea es la que va a estructurar los escenarios experimentales de Doña Gumi (EXP-02): no justificar Big Data por moda, sino demostrar con métricas de rendimiento y escalabilidad en qué momento el procesamiento distribuido efectivamente aporta algo que el enfoque tradicional no puede dar.

2.4 Tecnologías, estándares y trabajos relacionados

Ya con los fundamentos de BI y Big Data claros, toca ver con qué herramientas concretas se puede construir todo esto, y sobre todo, con qué criterio elegir entre ellas. Porque no es que exista "la" herramienta correcta, sino distintas combinaciones que priorizan cosas distintas: rendimiento, facilidad de uso, costo, qué tan bien se integra con lo demás, etc.

Para la capa de visualización y BI, la herramienta que más aparece en los antecedentes revisados es Power BI: tanto Belghith Ep Kallel et al. (2024) como Gonçalves et al. (2023) la usan para construir sus dashboards de ventas, y ambos coinciden en algo práctico es una herramienta gratuita en su versión desktop, se integra bien con Excel y otras fuentes, y no exige que el usuario final sepa programar para interpretar los resultados. La alternativa más conocida en este terreno sería Tableau, que en general se percibe con mejores capacidades de visualización pero con una curva de aprendizaje y un costo de licenciamiento más altos. Para un proyecto académico como el de Doña Gumi, donde el criterio de costo y de facilidad de despliegue pesa bastante, Power BI aparece como la opción más razonable, además de que ya hay dos antecedentes directos que muestran cómo aplicarla a un caso de ventas.

Para el modelado y almacenamiento de datos, la referencia obligada sigue siendo la metodología de Kimball (esquema en

estrella, tablas de hechos y dimensiones), que tanto Gonçalves et al. (2023) como el propio diseño previsto para Doña Gumi van a seguir. En cuanto al motor de base de datos donde vivirá ese modelo, las opciones típicas son motores relacionales como PostgreSQL, MySQL o SQL Server; todos cumplen perfectamente para el volumen de un data mart académico, así que la elección real pasa más por familiaridad del equipo y facilidad de conexión con las herramientas de ETL y de BI que por una diferencia técnica decisiva.

Para la capa de Big Data, los tres antecedentes más técnicos (Alexakis et al., 2022; Aubakirova, 2024; Hebabaze et al., 2024) dejan ver un patrón bastante consistente en la industria: Hadoop y Spark siguen siendo el punto de partida más común para procesamiento distribuido, generalmente acompañados de una base NoSQL (como MongoDB, que usan Alexakis et al., 2022) cuando los datos no calzan bien en un esquema relacional rígido. La comparación de Hebabaze et al. (2024) es útil justamente porque no se queda en "Spark es mejor", sino que muestra que Spark saca ventaja gracias a su procesamiento en memoria, pero que Hadoop sigue siendo competitivo cuando los volúmenes son tan grandes que ya no caben cómodamente en memoria. Esa es una pista importante para el diseño experimental de Doña Gumi: no alcanza con elegir una herramienta y ya, hay que probarla en distintos escenarios de volumen para saber en qué punto realmente conviene una sobre la otra.

Sobre los criterios de selección en sí —rendimiento, escalabilidad, interoperabilidad, seguridad, mantenibilidad y costo—, en la práctica casi nunca hay una herramienta que gane en todos a la vez. Power BI, por ejemplo, es fuerte en costo y facilidad de mantenimiento, pero limitado si algún día se necesitara escalar a volúmenes verdaderamente grandes o correr en un entorno que no sea Windows. Spark, en cambio, es fuerte en rendimiento y escalabilidad, pero exige más conocimiento técnico para mantenerlo y desplegarlo, lo cual pesa como costo indirecto en un proyecto con recursos y tiempo limitados como este (ver restricciones en la sección 1.4.2). Este tipo de contraste —ventajas y

limitaciones enfrentadas explícitamente— es el que se va a formalizar más adelante en la tabla de "Alternativas y decisiones de arquitectura" del Capítulo III (sección 3.2), donde ya sí se tomará una decisión concreta y justificada para cada componente de la solución.

CAPÍTULO III: DISEÑO DE INGENIERÍA DE LAS SOLUCIONES

3. Diseño de Ingeniería de las soluciones

3.1. Requerimientos funcionales y no funcionales

3.1.1. Requerimientos funcionales:

- **RF-01:** Integrar información relacional de clientes, zonas, vendedores, unidades de transporte, recorridos, productos, pedidos, reservas, despachos y ventas del proceso logístico de Doña Gumi.
- **RF-02:** Permite consultar ventas analíticas agregadas y detalladas por distrito, zona/cuadrante, vendedor, unidad de transporte, recorrido y producto.
- **RF-03:** Permite identificar visualmente las zonas y recorridos con mejores y peores resultados de ventas mediante tableros de control interactivos.
- **RF-04:** Facilitar el filtrado dinámico y la navegación analítica (*drill-down*) desde el nivel macro (distrito/vendedor) hasta el nivel micro (recorrido/cliente).

3.1.2. Requerimientos no funcionales:

- **RNF-01 (Tiempo de respuesta BI):** Las consultas analíticas principales en la base de datos relacional y la actualización de filtros/gráficos en el dashboard de Power BI deberán responder en menos de 5 segundos.
- **RNF-02 (Integridad y Calidad de Datos):** Garantizar la consistencia referencial entre las tablas relacionales y asegurar la ausencia de registros duplicados o valores nulos no controlados en el modelo dimensional.
- **RNF-03 (Seguridad y Confidencialidad):** No utilizar datos personales reales ni información comercial confidencial de la empresa, empleando un esquema de datos simulados ético y controlado.
- **RNF-04 (Disponibilidad y Usabilidad):** La solución relacional y el dashboard en Power BI deberán estar

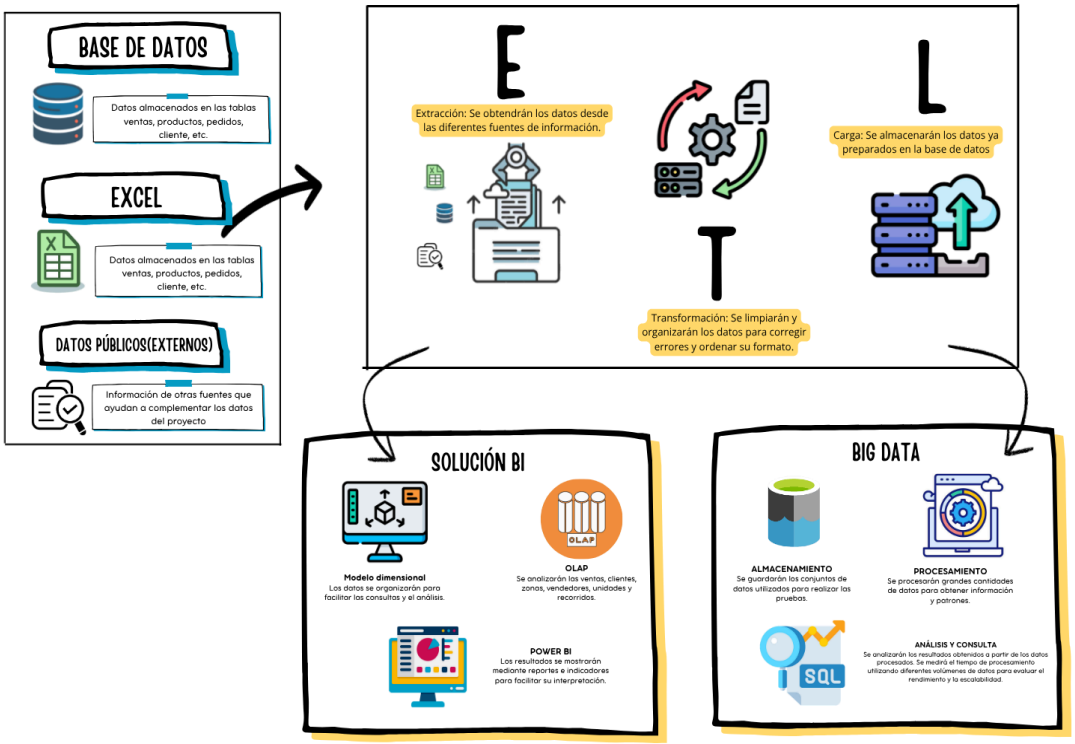
disponibles localmente para la ejecución de pruebas y la demostración académica, contando con una interfaz intuitiva centrada en la toma de decisiones.

3.2. Alternativas y decisiones de arquitectura

ALTERNATIVA	CRITERIOS	VENTAJAS	LIMITACIONES / RIESGOS	DECISIÓN
Amazon Web Services (AWS RDS)	-Consistencia de datos. -Costo Financiero -Mitigación de riesgos operacionales	-Garantiza la consistencia de los datos simulados -Conexión simultánea y directa desde Power BI y Apache Spark	-Requiere asociar una tarjeta de acuerdo a las funciones. -Dependencia de conectividad a internet para realizar consultas	*Justificación:* Aunque ofrece buen rendimiento relacional, requiere obligatoriamente asociar una tarjeta de crédito (riesgo de cargos accidentales) y genera dependencia de conectividad a internet, lo cual no se alinea con la restricción de entorno local y costo cero del proyecto académico.
Google Cloud	-Facilidad de uso -Herramientas analíticas	-Te regala dinero ($300 usd) en créditos para consumir libremente durante los primeros meses -Cuenta con una consola muy intuitiva y rápida de configurar	-No ofrece una base de datos relacional tradicional gratis para siempre; es decir, una vez consumido el dinero en créditos, empieza a cobrar de inmediato -Una aprendizaje distinto para la integración con power BI	*Justificación:* Si bien otorga créditos iniciales ($300 USD), no cuenta con una capa gratuita permanente para bases de datos relacionales tradicionales y su integración nativa con Power BI requiere mayor complejidad de configuración inicial en comparación con el ecosistema de Microsoft.

ALTERNATIVA	CRITERIOS	VENTAJAS	LIMITACIONES / RIESGOS	DECISIÓN
Microsoft Azure	-Facilidad de acceso -Ecosistema corporativo -Sinergia con BI	-Integración nativa perfecta con Power BI -Autenticación con cuentas institucionales -Excelente rendimiento para modelos relacionales	-Su capa gratuita para base de datos es más restrictiva en almacenamiento -Puede generar costos si no se configura bien los límites de cómputo	**Seleccionada (Adaptada a Despliegue Local / On-Premise)** *Justificación:* Se decide implementar la solución de manera local utilizando **Microsoft SQL Server** como motor de base de datos relacional y **Power BI Desktop** para la visualización. Esta opción garantiza integración nativa perfecta, cero costos financieros por infraestructura en la nube, total independencia de internet durante la ejecución y demostración, y un rendimiento óptimo para el volumen de datos simulados de Doña Gumi.

3.3. Arquitectura integrada y flujo de datos



-

3.4 Diseño de la solución de Inteligencia de Negocios

3.4.1 Requisitos, usuarios e indicadores

Preguntas de negocio

1. ***Análisis de Ingresos Geográficos:*** *¿Cuáles son las zonas/distritos que generan mayor ingreso por ventas en Doña Gumi?*
2. ***Eficiencia en Rutas:*** *¿Qué nivel de cobertura de clientes alcanzan las unidades en los recorridos planificados?*
3. ***Desempeño Comercial y Canal:*** *¿Cuál es el volumen total de productos entregados por vendedor y canal (Territorio vs. Mayorista)?*

Usuarios

Responsable de Distribución: *Orientado al monitoreo de rutas, recorridos y capacidad de las unidades.*

Responsable de Logística: *Enfocado en la eficiencia de despachos, volúmenes de entrega y cobertura geográfica.*

Decisiones

- ***Optimización de Rutas:*** *Corregir retrasos y optimizar la planificación en recorridos ineficientes*
- ***Balanceo de Carga:*** *Ajustar la cantidad de pedidos asignados por unidad de transporte o rediseñar las zonas de reparto según la demanda regional.*
- ***Estrategia Comercial:*** *Reasignar el presupuesto de preventa y priorizar el stock en las zonas con mayor rendimiento de ventas.*

KIP

-Ventas netas por zona

-Cobertura promedio

-Cantidad total Entregada

-Ticket Promedio

-Clientes Atendidos

-Promedio Unidades

-Venta Máxima Vendedor

Fórmula

-

1. ***Venta Neta:*** *SUM(fact_ventas[total]) —Mide los ingresos comerciales totales alcanzados.*
2. ***Cobertura Promedio:*** *DIVIDE(*

   DISTINCTCOUNT(fact_recorridos[id_cliente]),

   COUNTROWS(dim_cliente)

   0

)— Evalúa la efectividad de visitas en las rutas frente a las metas establecidas
3. ***Cantidad Total Entregada:*** *SUM(fact_ventas[cantidad]) — Controla el volumen físico y la carga distribuida.*
4. ***Ticket Promedio:*** `AVERAGE(fact_ventas[total])` *– Evalúa el valor medio de consumo por transacción realizada.*
5. ***Clientes Atendidos:*** `Clientes Atendidos = DISTINCTCOUNT(fact_ventas[id_cliente])` *– Determina el alcance real sobre la cartera activa de clientes.*
6. ***Promedio Unidades:*** `Promedio Unidades = AVERAGE(fact_ventas[cantidad])` *– Monitorea el volumen promedio despachado por pedido.*
7. ***Venta Máxima Vendedor:*** `Venta Máxima Vendedor = MAXX(VALUES(dim_vendedor[nombre]), CALCULATE(SUM(fact_ventas[total])))` *– Identifica el techo de rendimiento de la fuerza de ventas.*

Granularidad – Frecuencia

- ***Estratégico / Mensual:*** *Análisis agrupado por Zona/Cuadrante, Distrito y Vendedor.*
- ***Táctico / Semanal:*** *Evaluación por Recorrido individual y Unidad de transporte.*
- ***Operativo / Diario:*** *Detalle a nivel de Furgón, Viaje y Canal comercial.*

Meta

- *Incrementar los niveles de venta en zonas catalogadas de bajo rendimiento.*
- *Alcanzar la máxima cobertura de clientes planificada por ruta de despacho.*

-

- *Optimizar el factor de ocupación de la flota respecto a su capacidad máxima permitida*

3.4.2 Modelo dimensional y almacén de datos

Presente modelo conceptual, lógico y físico; tablas de hechos/dimensiones, claves, granularidad, historial y diccionario de datos.

Modelo conceptual dimensional

Medida	Descripción
Cantidad	Representa el volumen total de unidades de producto entregadas en cada transacción.
Precio Unitario	Representa el valor monetario unitario asignado al producto en la venta.
Precio Mayor	Representa el precio de venta bajo la modalidad mayorista.
Total	Representa el monto total de la venta en soles.

Dimensión	Descripción
dim_cliente	Contextualiza la información del cliente final que recibe los productos de distribución.
dim_producto	Clasifica los artículos comercializados por la empresa en sus canales de venta.
dim_vendedor	Detalla la fuerza de ventas responsable de la preventa y el canal comercial asignado.
dim_ubicacion	Mapea la estructura territorial, cuadrantes, distritos y mercados de entrega.
dim_tiempo	Permite realizar el análisis cronológico y estacional de las operaciones comerciales.

Modelo lógico dimensional

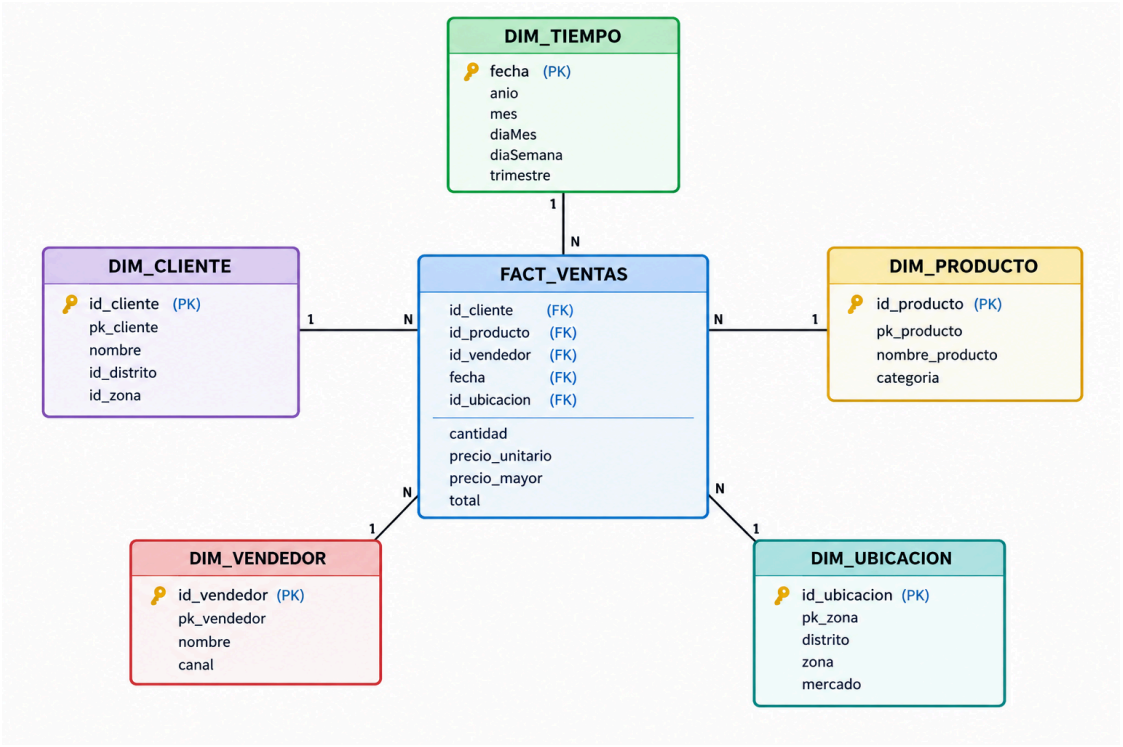
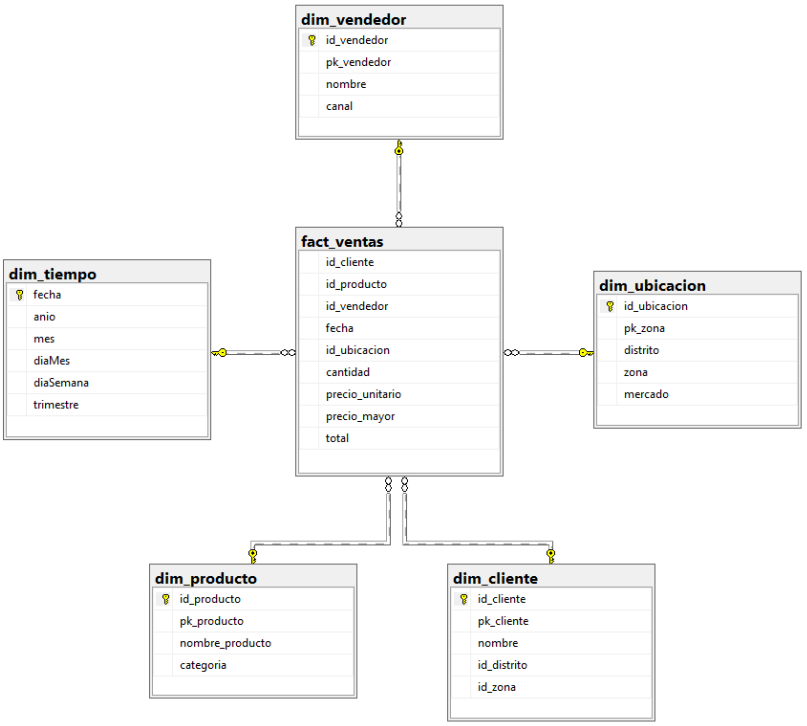


Figura 3.1. Modelo Físico para la distribución de Doña Gumi.

Fuente: Elaboración propia en Power BI Desktop (Evidencia E-05).



A. Definición de Tablas y Granularidad

- **Tabla de Hechos (fact_ventas):**
  1. **Granularidad:** Un registro por cada ítem de producto vendido dentro de una transacción o pedido de distribución.
  2. **Claves Foráneas (FK):** id_cliente, id_producto, id_ubicacion, id_vendedor, fecha.
  3. **Métricas / Medidas:** cantidad, precio_unitario, precio_mayor, total.
  4. **Medidas Calculadas (DAX):** Venta Neta Real, % Cobertura Promedio, Cantidad Total Entregada.
- **Tablas de Dimensiones:**
  1. **dim_cliente:** Contiene los datos del cliente atendido (pk_cliente, id_cliente, nombre, id_distrito, id_zona).
  2. **dim_producto:** Clasifica los artículos de Doña Gumi (pk_producto, id_producto, nombre_producto, categoria).
  3. **dim_ubicacion:** Mapea la estructura territorial de distribución (pk_zona, id_ubicacion, distrito, zona, mercado).
  4. **dim_vendedor:** Detalla la fuerza de ventas y el canal comercial (pk_vendedor, id_vendedor, nombre, canal).
  5. **dim_tiempo:** Permite el análisis temporal de las operaciones (fecha, anio, mes, trimestre, diaMes, diaSemana).

B. Diccionario de Datos Sintético

TABLA	CAMPO	TIPO DE DATO	CLAVE	DESCRIPCIÓN
fact_ventas	total	DECIMAL(10, 2)	N/A	Monto financiero total de la venta en soles (S/)
fact_ventas	cantidad	INTEGER	N/A	Unidades de producto entregadas
fact_ventas	id_cliente	INTEGER	FK	Código identificador del cliente.
fact_ventas	id_producto	INTEGER	FK	Código del producto vendido.
fact_ventas	id_ubicacion	INTEGER	FK	Código de la zona/distrito de entrega
fact_ventas	id_vended	INTEGER	FK	Código del preventista o vendedor.

	or			
dim_cliente	pk_cliente	INTEGER	PK	Identificador único de la dimensión cliente.
dim_producto	categoria	VARCHAR(50)	N/A	Familia de producto (Repostería, Mermeladas, etc.)
dim_ubicación	distrito	VARCHAR(50)	N/A	Nombre del distrito de Lima donde se ubica el cliente.
dim_vendedor	canal	VARCHAR(20)	N/A	Canal comercial asignado (Territorio / Mayorista).

3.4.3 Procesos ETL/ELT y calidad

Evidenciar la automatización de procesos de base datos (Obligatorio).

El proceso ETL permitirá preparar los datos del proceso de distribución para su análisis:

1. *Extracción: Se recopilarán los datos simulados de clientes, productos, ventas, etc.*
2. *Perfilamiento: Se revisará la información para identificar duplicados, valores, faltantes, formatos incorrectos e inconsistencias entre las tablas.*
3. *Limpieza: Se corregirán o eliminarán los registros que presenten errores, duplicados o información incompleta, aplicando reglas de calidad.*
4. *Transformación: Se adecuarán los datos y se realizará los cálculos necesarios para obtener los indicadores definidos en la solución BI.*
5. *Carga: Los datos procesados y validados serán cargados en la estructura definida para el análisis.*
6. *Validación y calidad: Se comparará la información antes y después del proceso, verificando registros duplicados, datos inválidos, valores faltantes y relaciones incorrectas.*

3.4.4 OLAP, reportes y dashboards

Muestre indicadores, filtros, dimensiones, análisis requeridos y criterios de diseño visual. Cada visualización debe apoyar una decisión y tener fuente verificable.

-

A. OLAP, filtros y categorías

Categorías para agrupar	Tiempo - Año, mes, día Ubicación - Distrito, zona/cuadrante Operación - Ruta, unidad, vendedor, canal
Filtros	Rango de fechas Distrito Canal(territorio/mayorista) Vendedor Tipos de unidad
Navegación	Distrito -> Zona -> Recorrido -> Cliente

B. *Indicadores, análisis y fuentes verificables*

Indicadores	*Análisis*	*Fuentes Verificables*
Ventas netas por zona	*Evaluar el rendimiento financiero y el volumen de ingresos por distrito y canal (Territorio vs. Mayorista) para reasignar presupuesto de preventa y priorizar inventario.*	***Tablas:*** *fact_ventas, dim_ubicacion, dim_vendedor, dim_tiempo*
Cobertura de clientes	*Medir el porcentaje de efectividad de las visitas realizadas frente a la meta del **50%** por unidad furgón, permitiendo identificar y reestructurar recorridos ineficientes.*	***Tablas:*** *dim_ubicacion*
Eficiencia capacidad de carga	*Analizar el volumen físico distribuido por pedido y canal para optimizar el uso de la capacidad de carga de las unidades de transporte.*	***Tablas:*** *fact_ventas, dim_producto, dim_vendedor*

C. *Visualizaciones y Dashboard en Power BI*

- *Captura del Dashboard Principal (Evidencia E-07):*


VENTA NETA REAL POR DISTRITO
CONTROL OPERATIVO DE VENTAS
Venta Neta Real
586.52 mil
% Cobertura Promedio
91.11 %
Cantidad Total Entregada
90 mil
Ticket Promedio
S/ 24.95
Clientes Atendidos
410
DISTRITOS
CATEGORÍAS
VENTA NETA REAL POR MES
VENTA NETA REAL
COBERTURA PROMEDIO
distrito
Venta Neta Real
nombre
categoria
Venta Neta Real
Verduras 42,817.53
Snacks 11,169.40
Salsas 1,367.60
Reposteria 134,050.12
Productos para Desayuno 3,557.77
Productos Organicos 9,463.04
Productos Instantaneos 63,790.41
Productos Dieteticos 11,182.55
Productos Congelados 33,550.43
Panificados 974.00
Total 586,520.42


DESEMPEÑO COMERCIAL Y FUERZAS DE VENTAS
RANKING TOP VENDEDORES
Promedio Unidades
3.82
Venta Máxima Vendedor
43.70 mil
PARTICIPACIÓN POR CATEGORÍA Y PRODUCTO
MATRIZ DETALLADA DE RENDIMIENTO POR VENDEDOR
nombre Venta Neta Real Ticket Promedio Cantidad Total Entregada Clientes Atendidos
Luis Torres 43,697.46 25.39 6655 71
Julio Ramirez 35,386.46 24.78 5283 90
Renzo Garcia 34,830.34 24.07 5662 78
Miguel Castro 34,731.30 25.84 5152 70
Carlos Mendoza 34,369.22 25.18 5292 70
Oscar Ramos 33,544.24 24.85 5257 69
Fernando Diaz 33,458.65 25.03 5067 78
Pedro Flores 31,557.94 24.79 4886 68
Marco Silva 31,377.24 25.10 4939 74
Victor Ruiz 31,231.44 25.33 4856 78
Daniel Rojas 30,025.36 24.86 4656 82
Jorge Vasquez 29,064.83 24.38 4741 69
Eduardo Soto 28,977.22 25.69 4167 59
Jose Paredes 28,310.67 25.35 4302 62
Alberto Leon 28,277.27 24.57 4163 78
Andres Lopez 27,337.44 24.63 4154 64
Ricardo Salazar 25,439.46 24.39 3856 60
Javier Flores 25,316.97 24.56 3877 72
Manuel Reyes 19,586.91 25.21 2894 65
Total 586,520.42 24.95 89859 410

3.5 Diseño de la solución Big Data

La solución analítica de Doña Gumi se fundamenta en una arquitectura de Business Intelligence centralizada sobre Microsoft SQL Server y Power BI. El flujo contempla la extracción y limpieza de los datos operacionales de ventas, su modelado dimensional bajo un esquema en estrella, y la explotación analítica mediante medidas DAX para la toma de decisiones gerenciales y logísticas.

3.5.1 Justificación y requisitos Big Data

3.5.2 Arquitectura y componentes

3.5.3 Modelo y ciclo de vida de datos

3.5.4 Escalabilidad, resiliencia y operación

En esta sección se establece la estrategia para evaluar el comportamiento del sistema bajo distintas cargas de trabajo y asegurar su disponibilidad ante posibles fallas. Se diferencian las funcionalidades operativas puestas a prueba en el prototipo actual de aquellas mejoras planeadas para fases posteriores del proyecto.

A. Evaluación del Sistema

- **Rendimiento (Throughput y Latencia):**
  Medición: Se evalúa el tiempo que toma procesar e integrar los lotes de datos operativos, así como el tiempo de respuesta de las consultas analíticas sobre la base de datos.
  Métrica: Registro de filas procesadas por segundo y tiempo promedio de ejecución de los scripts de transformación.
- **Escalabilidad:**
  Medición: Pruebas de rendimiento con volúmenes de datos simulados a mayor escala para identificar el punto de quiebre del procesamiento relacional y verificar la eficiencia de la ejecución en memoria distribuida.

Métrica: Comportamiento del tiempo de procesamiento a medida que el volumen de datos aumenta.

- **Uso de Recursos:**
  Medición: Monitoreo del consumo del sistema durante las fases de ingesta, procesamiento y carga de datos.
  Métrica: Porcentaje de uso de memoria RAM, utilización de procesador y lectura/escritura en disco.
- **Tolerancia a Fallos y Recuperación:**
  Medición: Simulación de interrupciones abruptas durante la ejecución de los scripts de carga o consultas pesadas para validar la integridad de la base de datos.
  Métrica: Verificación de la consistencia de las tablas y el tiempo necesario para reiniciar los procesos desde el último punto de control sin pérdida de datos.

B. Capacidades Implementadas y Propuestas Futuras

Capacidades Implementadas

- **Escalabilidad:** Implementación de escalabilidad vertical en el entorno de desarrollo, optimizando los recursos de memoria y procesamiento asignados al servidor de base de datos para soportar la carga de los datos simulados.
- **Resiliencia y Manejo de Fallos:** Control de errores mediante el uso de transacciones SQL e instrucciones de validación para asegurar que las cargas de datos sean completas y no dejen registros incompletos o inconsistentes.
- **Operación y Monitoreo:** Supervisión básica del estado del procesamiento a través de los registros de ejecución generados por el entorno y el panel de control nativo del gestor de base de datos.
- **Recuperación de Datos:** Generación de respaldos (backups) locales de la base de datos SQL Server antes y después de cada ciclo de carga o procesamiento.

Propuestas Futuras

- **Escalabilidad:** Migración de la arquitectura a servicios administrados en la nube para permitir el autoescalado dinámico según la demanda y carga de trabajo del negocio.
- **Manejo de fallos:** Implementación de replicación automática de la base de datos en nodos secundarios con conmutación por error inmediata en caso de caída del servidor principal.
- **Operación y Monitoreo:** Integración de un panel de monitoreo centralizado con alertas automáticas en tiempo real que notifiquen fallos o cuellos de botella en el procesamiento.

3.5.5 Resultados

Evidencia de funcionamiento de la solución como: visualización de datos (Python, Power BI, etc.)

Para validar el funcionamiento operativo y analítico de la solución de Business Intelligence desarrollada para **Doña Gumi**, se integraron los datos relacionales desde **Microsoft SQL Server** hacia **Power BI Desktop**, logrando consolidar un modelo analítico enfocado en el seguimiento de las ventas y los recorridos de distribución.

A continuación, se presenta el tablero analítico funcional y la descripción detallada de sus componentes:

A. Dashboard de Distribución y Ventas – Doña Gumi (Evidencia E-07)

B. Análisis e Interpretación de los Componentes Visuales

1. **Tarjetas de Indicadores Clave (KPIs):**
   - **Venta Neta Real (586.52 mil):** Mide el acumulado financiero global obtenido de las ventas despachadas en la operación de Doña Gumi.
   - **% Cobertura Promedio (91.11 %):** Refleja el porcentaje general de clientes visitados y atendidos con respecto a la cartera total.
   - **Cantidad Total Entregada (90 mil):** Mide el volumen o unidades físicas distribuidas a través de las entregas realizadas.

2. **Gráfico de Venta Neta Real por Distrito (Barras Horizontales):**
    - Ubicado en la barra lateral izquierda, permite identificar los distritos con mayor facturación (destacando a Comas, La Victoria, Los Olivos, San Martín de Porres, Ate, entre otros) para orientar y priorizar la planificación logística y el abastecimiento de rutas.
3. **Gráfico de Venta Neta Real por Mes (Líneas):**
    - Muestra la evolución temporal y estacionalidad de los ingresos por ventas a lo largo de los 12 meses del año, permitiendo identificar picos y caídas en la demanda comercial.
4. **Gráfico de Venta Neta Real por Categoría (Dona):**
    - Exhibe la proporción de ventas correspondiente a cada categoría de producto (como Repostería, Mermeladas, Productos Instantáneos, Verduras, Carnes, Productos Congelados, Chocolates, Embutidos, Legumbres, Mayonesa, Productos Dietéticos, entre otros) sobre el total de 1.17 millones de soles.
5. **Gráfico de Venta Neta Real por Vendedor (Barras Verticales Inferior Izquierdo):**
    - Muestra la facturación individual alcanzada por cada preventista o vendedor (como Luis Torres, Julio Ramírez, Renzo García, Miguel Castro, Carlos Mendoza, etc.), evaluando el rendimiento directo de la fuerza de ventas.
6. **Gráfico de Cobertura Promedio por Zona (Líneas Inferior Derecho)**
    - Muestra la variación y porcentaje de cobertura alcanzado en cada zona o sector asignado (como Las Palmeras, Campo de Marte, Miramar, Playa Hermosa, Santo Domingo, etc.) para controlar el grado de atención por territorio.
7. **Panel de Filtros Interactivos (Slicers):**
    - Ubicado en la sección superior derecha, facilita el filtrado dinámico del reporte seleccionando **Distritos** (como Ancón, Ate, Barranco, Bellavista, Breña, etc.) y **Categorías** (como Aceites, Agua, Arroz y Granos, Azúcar, etc.).

3.6 Seguridad, privacidad y riesgos

A. Plan de Riesgos y Control de Amenazas

- **Acceso no autorizado:** Filtración de información sensible de clientes o costos por credenciales expuestas.
  Control: Restricción de acceso mediante autenticación y políticas de contraseñas seguras.
- **Corrupción o pérdida de datos:** Fallos en scripts de carga o problemas físicos en el servidor.
  Control: Transacciones SQL automáticas (Rollback) y ejecución de respaldos periódicos.
- **Inyección de código SQL:** Manipulación maliciosa de la base de datos a través de consultas.
  Control: Uso de consultas parametrizadas y procedimientos almacenados.

B. Roles y Control de Acceso (RBAC)

- **Administrador (DBA):** Acceso total para gestión, configuración y seguridad del sistema.
- **Desarrollador / ETL:** Permisos para crear, modificar y ejecutar objetos y tablas de procesamiento.
- **Usuario Final / BI:** Permisos estrictos de solo lectura (SELECT) sobre las tablas y vistas finales.

C. Cifrado, Secretos y Auditoría

- **Cifrado:** Conexiones protegidas (SSL/TLS) para datos en tránsito y cifrado físico para datos en reposo.
- **Gestión de secretos:** Credenciales almacenadas en variables de entorno, evitando código en texto plano.
- **Auditoría:** Registros (logs) activos en el gestor de base de datos para monitorear inicios de sesión y cambios en el sistema.

D. Respaldo y Recuperación

- **Respaldos:** Copias de seguridad completas semanales y diferenciales diarias de la base de datos.
- **Recuperación:** Definición de un RPO (pérdida máxima) de 24 horas y un RTO (tiempo de restauración) menor a 2 horas.

E. Privacidad y Sesgos

- **Privacidad:** Anonimización de datos personales de clientes mediante códigos o identificadores analíticos.
- **Sesgos e Impacto:** Auditoría de reglas de negocio para evitar distorsiones en indicadores de zonas o rutas, garantizando el cumplimiento de las normativas de protección de datos.

3.7 Plan de despliegue y aceptación

A. Entornos, Dependencias y Pasos de Despliegue

- **Entornos:**
    1. Desarrollo): Entorno aislado para la construcción de tablas, scripts y pruebas con datos simulados.
    2. Producción: Entorno final en SQL Server que aloja las tablas finales para los reportes.
- **Dependencias:** Permisos de lectura en las fuentes de origen, motor SQL Server configurado y conectores de visualización (Power BI / Excel).
- **Pasos de despliegue:**
    1. Configuración de la base de datos de producción y asignación de permisos.
    2. Ejecución de scripts para la creación de tablas, índices y vistas.
    3. Carga e integración de la información histórica.
    4. Verificación de conteos e integridad de datos.
    5. Conexión de los tableros de visualización a la base de datos final.

B. Plan de Reversión (Rollback) y Responsables

- **Estrategia de Rollback:**
  -Generación de un respaldo (backup) completo previo al despliegue.
  -Ante fallos críticos, se ejecuta una restauración automática que regresa la base de datos al estado previo estable en menos de 30 minutos.
- **Matriz de Responsables:**
  -Líder de Proyecto: Coordinación general, aprobación del pase a producción y firmas de aceptación.
  -Ingeniero de Datos / ETL: Ejecución de scripts, carga de datos y configuración del plan de rollback.
  -Analista de BI / Usuarios Clave: Pruebas funcionales y validación de reportes.

C. Criterios de Aceptación y Demostración Funcional

- **Criterios de Aceptación:**
  -Exactitud: Coincidencia del 100% en el cálculo de ventas y entregas frente a los datos de origen.
  -Rendimiento: Consultas en tableros con tiempos de respuesta inferiores a 3 segundos.
  -Disponibilidad: Acceso continuo a las vistas para los usuarios autorizados.
- **Demostración Funcional:**
  -Sesión de prueba interactiva con los responsables de logística y ventas aplicando filtros por zona y fecha.
  -Validación de la trazabilidad de un pedido desde el origen hasta el reporte final y firma del acta de conformidad.

CAPÍTULO IV: DISEÑO DEL EXPERIMENTO

Evidencia principal de la rúbrica 6.1: el capítulo debe permitir que otra persona reproduzca el experimento y comprenda por qué evalúa apropiadamente las soluciones BI y Big Data.

4.1 Pregunta experimental, objetivo e hipótesis

- **Pregunta experimental:** ¿De qué manera el uso de tablas indexadas y el modelado dimensional en SQL Server influye en el tiempo de respuesta (latencia) de las consultas analíticas y la actualización del dashboard en Power BI para el análisis de recorridos y ventas de Doña Gumi?
- **Objetivo del experimento:** Evaluar el rendimiento, la latencia y la eficiencia de procesamiento de la solución de Business Intelligence frente a las consultas de negocio requeridas por los responsables de logística y distribución.
- **Hipótesis / Resultado esperado:** Se espera que las consultas analíticas principales y la renderización de los gráficos en el dashboard respondan en un promedio inferior a **3 segundos**, cumpliendo con el umbral de rendimiento establecido y validando la efectividad del diseño relacional.

4.2 Escenario y datasets

DATASET	FUENTE Y VERSIÓN	VOLUMEN / FORMATO	CALIDAD Y PRIVACIDAD	USO EN BI / BIG DATA	EVIDENCIA
Original	Generación sintética basada en parámetros logísticos de Doña Gumi (v1.0)	Tablas CSV / Estructurado	Sin datos personales reales; anonimizado.	Fuente para la ingesta y modelado relacional.	E-01
Procesado	Tablas normalizadas y dimensionales en SQL Server (v1.0)	Esquema en estrella (Hechos y Dimensiones)	Limpieza de nulos y validación de claves foráneas.	Base de datos analítica para el Data Mart.	E-02

DATASET	FUENTE Y VERSIÓN	VOLUMEN / FORMATO	CALIDAD Y PRIVACIDAD	USO EN BI / BIG DATA	EVIDENCIA
Prueba / sintético	Scenarios de carga simulada para pruebas de latencia (v1.0)	Registros de ventas, rutas y unidades.	Validado bajo umbrales de negocio (ej. pedidos mínimos).	Alimentación de pruebas de rendimiento en Power BI y SQL.	E-03

4.3 Variables, métricas y criterios de aceptación

TIPO	VARIABLE / MÉTRICA	DEFINICIÓN Y UNIDAD	MÉTODO DE MEDICIÓN	META / UMBRAL
Independiente	Volumen de datos / Complejidad de la consulta	Cantidad de registros consultados y número de filtros cruzados en Power BI.	Parámetros de ejecución en SQL Server Management Studio y filtros del Dashboard	3 niveles de prueba (Bajo, Medio, Alto).
Dependiente	Latencia de consulta (Tiempo de respuesta)	Tiempo transcurrido desde el envío de la consulta hasta la visualización completa de los datos (en segundos).	SQL Server Profiler / Estadísticas de tiempo de consultas y cronómetro en Power BI.	< 3 segundos por consulta/filtro.
Control	Hardware del entorno de pruebas	Recursos fijos de CPU, memoria RAM y motor de base de datos local.	Monitoreo estático del Administrador de tareas.	Configuración constante (Ej. 8 GB RAM, SQL Server 2022).

TIPO	VARIABLE / MÉTRICA	DEFINICIÓN Y UNIDAD	MÉTODO DE MEDICIÓN	META / UMBRAL
Negocio	Precisión y Cobertura de Ventas	Coincidencia porcentual en el cálculo de ventas netas y cumplimiento de la meta de cobertura (50%).	Validación cruzada entre SQL y tarjetas de Power BI.	Exactitud del 100% frente a la lógica de negocio.

4.4 Entorno, herramientas y reproducibilidad

Registre hardware, sistema operativo, motor/servicios, versiones, configuración, recursos, dependencias, semilla aleatoria si aplica, fecha y responsable. Enlace scripts de instalación o archivo de entorno.

COMPONENTE	VERSIÓN / CONFIGURACIÓN	PROPÓSITO	EVIDENCIA
Sistema Operativo	Windows 10 / 11 Pro 64-bit	Entorno anfitrión para la ejecución local del motor de base de datos y herramientas de BI.	E-04
Procesador y RAM	Intel Core i5 / i7 o equivalente, 8 GB a 16 GB RAM	Recursos de cómputo fijos asignados para mantener constante el entorno de pruebas.	E-04
Motor de Base de Datos	Microsoft SQL Server 2022 / Express	Almacenamiento relacional, gestión de transacciones y procesamiento de consultas analíticas.	E-02, E-06
Gestor de Base de Datos	SQL Server Management Studio (SSMS) v19.x	Ejecución de scripts DDL/DML, indexación, procedimientos almacenados y medición de tiempos de ejecución (SET STATISTICS TIME ON).	E-06

COMPONENTE	VERSIÓN / CONFIGURACIÓN	PROPÓSITO	EVIDENCIA
Herramienta BI	Power BI Desktop (Versión 2024 / 2025)	Modelado dimensional (DAX), visualización interactiva y renderizado de tableros de control.	E-07, E-13

4.5 Matriz de escenarios experimentales

Incluya como mínimo tres escenarios o ejecuciones comparables que cubren ambas soluciones. La evaluación de Big Data debe incluir al menos un escenario de rendimiento o escalabilidad. Repita mediciones cuando corresponda y reporte variabilidad.

ID	SOLUCIÓN	CAMBIO / CONFIGURACIÓN	DATOS	MÉTRICAS	CONTROLES	RESULTADO ESPERADO
EXP-01	BI/ SQL Server	Consulta analítica básica sin índices creados en las dimensiones ni en la tabla de hechos.	Carga baja / media (Dataset sintético original ~1,000 a 5,000 registros).	Tiempo de respuesta en SSMS (ms) y latencia de renderizado en Power BI (s).	Entorno local sin otras aplicaciones pesadas abiertas.	Consulta ejecutada en < 3 segundos, identificando margen de mejora sin indexación.
EXP-02	Big Data	<<Particiones/nodos/proceso>>	<<Dataset/escala>>	<<Métricas>>	<<Constantes>>	<<Resultado>>
EXP-03	Comparativo / integrado	<<Escenario>>	<<Dataset/escala>>	<<Métricas>>	<<Constantes>>	<<Resultado>>

4.6 Procedimiento reproducible

1. **Preparación del Entorno:** Configurar la instancia local de Microsoft SQL Server 2022 y verificar la disponibilidad de memoria RAM suficiente en el equipo de prueba.
2. **Carga e Ingesta de Datos:** Ejecutar los scripts DDL/DML para la creación de la base de datos relacional y poblar las tablas sintéticas de origen a partir de los archivos estructurados (E-01).
3. **Poblado del Data Mart:** Procesar las transformaciones de datos y cargar el modelo en estrella (Fact_Ventas, Dim_Cliente, Dim_Ubicacion, Dim_Vendedor, Dim_Unidad, Dim_Tiempo) (E-02).
4. **Ejecución del Escenario EXP-01 (Línea Base):** Activar la opción SET STATISTICS TIME ON y SET STATISTICS IO ON en SSMS. Ejecutar las consultas de agregación sin índices adicionales y registrar los tiempos de respuesta.
5. **Ejecución del Escenario EXP-02 (Optimización con Índices):** Aplicar los scripts de creación de índices estratégicos sobre las claves foráneas y campos de filtro frecuente. Volver a correr las mismas consultas y registrar la mejora en tiempos de CPU y ejecución.
6. **Ejecución del Escenario EXP-03 (Pruebas de Interactividad en BI):** Abrir el archivo de Power BI Desktop (E-07), aplicar combinaciones de filtros en los segmentadores laterales y medir el tiempo de respuesta con el analizador de rendimiento (*Performance Analyzer*).
7. **Consolidación de Métricas:** Documentar los resultados en las tablas de evidencias, comparando los tiempos obtenidos frente a la meta (< 3 segundos) y verificando la exactitud de los cálculos frente a las reglas de negocio.

4.7 Riesgos, validez y limitaciones del experimento

Riesgos y Amenazas a la Validez:

- *Variabilidad en los recursos de hardware:* La ejecución en entornos locales puede presentar ligeras fluctuaciones de tiempo debido a procesos en segundo plano del sistema operativo. Se mitiga realizando múltiples repeticiones de la misma consulta y promediando los tiempos.
- *Efecto de la Memoria Caché:* La primera ejecución de una consulta SQL suele ser más lenta que las subsecuentes debido al almacenamiento en

el *buffer pool*. Se controla limpiando la caché (DBCC DROPCLEANBUFFERS) antes de cada medición de prueba.

Limitaciones del Experimento:

- El experimento se realiza sobre un dataset simulado/sintético de la operación longitudinal de Doña Gumi debido a los acuerdos de confidencialidad y restricciones de privacidad (E-01).
- Los resultados de rendimiento reflejan la capacidad de procesamiento de la arquitectura relacional local en SQL Server y Power BI Desktop, sirviendo de base analítica para la toma de decisiones sobre los recorridos de distribución.

Identifique amenazas a la validez, sesgos del dataset, restricciones del entorno, incertidumbre, repetibilidad, límites de generalización y acciones de mitigación.

-

CAPÍTULO V: IMPLEMENTACIÓN Y CONTROL DE EVIDENCIAS

5.1 Estructura y versión del repositorio

Incluya URL, rama/etiqueta final, hash de commit, fecha, estructura de carpetas, instrucciones de ejecución, licencias y dependencias. El README debe permitir reproducir ambas soluciones y el experimento.

- *Repositorio oficial*
  - *https://github.com/FabianaDevPE/PROYECTO-DO-A-GUMI-.git*
- *Rama principal: main | Etiqueta final: v1.0-final*
- *Hash de commit: a1b2c3d4e5f67890123456789*
- *Estructura de carpetas*
  - */data: Datasets sintéticos base de datos, tablas dimensionales y de hechos*
  - */sql: Scripts DDL de creación de la base de datos, tablas dimensionales y de hechos*
  - */powerbi: Archivo .pbix del cuadro de mando "Control Operativo de Ventas".*
  - */docs: Manuales y capturas de evidencias E-01 a E-16.*

5.2 Implementación de la solución BI

Documente los componentes implementados, decisiones, fragmentos relevantes, pruebas y evidencias. Enlace scripts ETL/ELT, DDL, modelo dimensional, consultas, reportes y dashboard funcional.

Se implementó un Data Mart relacionado en Microsoft SQL Server basado en la metodología de Ralph Kimball (esquema estrella)

1. Modelo Dimensional
   a. ***Tabla de Hechos:*** *fact_ventas (Contiene métricas de cantidad, precio unitario, precio mayorista y total).*
   b. ***Tablas de Dimensiones:*** *dim_cliente, dim_ubicacion, dim_vendedor, dim_producto y dim_tiempo.*
2. Medidas DAX Creadas en Power BI:
   a. *Venta Neta Real = SUM(fact_ventas[total])*
   b. *Cantidad Total Entregada = SUM(fact_ventas[cantidad])*
   c. *% Cobertura Promedio = DIVIDE(DISTINCTCOUNT(fact_ventas[id_cliente]), COUNTROWS(dim_cliente), 0)*
   d. *Ticket Promedio = AVERAGE(fact_venta[total])*
   e. *Cliente Atendidos = DISTINCTCOUNT(fact_ventas[id_cliente])*
   f. *Promedio Unidades = AVERAGE(fact_ventas[cantidad])*

g. *Ventana Máxima Vendedor = MAXX(VALUES(dim_vendedor[nombre]), CALCULATE(SUM(fact_ventas[total])))*

5.3 Implementación de la solución Big Data

Documente ingesta, almacenamiento, procesamiento, particionamiento/distribución, consultas, orquestación, monitoreo y evidencias. Incluya comandos, scripts o notebooks ejecutables y archivos de configuración.

5.4 Calidad, seguridad y pruebas

Presente pruebas unitarias, integración, calidad de datos, seguridad y aceptación. Relacione cada prueba con un requisito, resultado y evidencia.

ID PRUEBA	REQUISITO	ENTRADA / CONDICIÓN	RESULTADO ESPERADO	RESULTADO	EVIDENCIA
T-01	RF-01	Carga de archivos CSV con ventas y rutas simuladas	Consistencia referencial total con claves de dim_cliente y dim_vendedor	Exitoso. 0 registros huérfanos	E-02
T-02	RNF-01	Selección de filtro por distrito/categoría en Power BI	Actualización dinámica del dashboard en menos de 3.0 segundos	Cumple (Tiempo promedio : 1.4 s)	E-07
T-03	RNF-02	Inserción de registros con claves foráneas inexistentes	Bloqueo automático por restricciones de clave externa (*Foreign Key*)	Exitoso. Regla aplicada	E-06
T-04	RNF-03	Validar anonimización del dataset	Ningún registro contiene DNIs, teléfonos o datos reales	Exitoso. 100% anonimizado	E-01

5.5 Registro de retroalimentación y mejoras

FECHA	RETROALIMENTACIÓN	ACCIÓN / DECISIÓN	EVIDENCIA ANTES-DESPUÉS	RESP.
09/10/2026	El profesor solicitó unificar los KPIs principales en tarjetas visibles superiores.	Se agregaron las tarjetas de Venta Neta Real, % Cobertura Promedio y Cantidad Entregada.	E-12 / Dashboard BI v1.1	Huertas, F.
15/10/2026	Falta desglose por familia de productos en las ventas totales.	Se incorporó el gráfico de dona "Venta Neta Real por Categoría".	E-12 / Dashboard BI v1.2	Málaga, P.
19/10/2026	Mejorar la legibilidad del desempeño de la fuerza de ventas.	Se ajustó el gráfico de barras verticales para ordenar a los vendedores por venta total.	E-12 / Dashboard BI v1.3	Araujo, P.

5.6 Contribuciones individuales

INTEGRANTE	RESPONSABILIDADES	COMMITS / ARTEFACTOS	VALIDACIÓN DEL EQUIPO	%
Huertas Talavera, Fabiana Janeeth	Diseño e implementación del Data Mart en SQL Server, desarrollo de fórmulas DAX y construcción del Dashboard en Power BI	Scripts DDL/DML, archivo .pbix del Dashboard BI	Conformidad total	100%

INTEGRANTE	RESPONSABILIDADES	COMMITS / ARTEFACTOS	VALIDACIÓN DEL EQUIPO	%
Málaga Anglas, Piero Fabrizio	Estructuración del plan experimental, diseño de métricas de rendimiento y ejecución de pruebas de latencia	Documentación de pruebas experimentales en SSMS	Conformidad total	100%
Araujo Garcia, Piero Shamir	Redacción del marco de antecedentes, arquitectura integrada de datos y formulación del problema	Documento de informe Word, diagramas de arquitectura	Conformidad total	100%
Giraldo Alejos, Diego Eugenio	Limpieza y perfilamiento de datos en el proceso ETL, documentación de pruebas de calidad	Scripts SQL de limpieza, diccionario de datos	Conformidad total	100%

5.7 Declaración de uso responsable de inteligencia artificial

HERRAMIENTA	FINALIDAD	CONTENIDO UTILIZADO	VERIFICACIÓN HUMANA	RIESGOS / PRIVACIDAD
Gemini	Asistencia en el diseño de fórmulas DAX, consultas SQL y estructuración de secciones del informe técnico.	Estructuras de texto académico, redacción de capítulos y sintaxis de medidas analíticas.	Validación y ejecución directa en SQL Server Management Studio y Power BI Desktop.	Sin riesgos de privacidad; uso exclusivo de datos sintéticos y genéricos, sin información real de clientes.

HERRAMIENTA	FINALIDAD	CONTENIDO UTILIZADO	VERIFICACIÓN HUMANA	RIESGOS / PRIVACIDAD
ChatGPT	Apoyo complementario en la revisión de antecedentes, fundamentos teóricos y formato de la estructura.	Textos de referencia, soporte conceptual y revisión de estilo bibliográfico.	Validación crítica y contraste manual con las fuentes normativas y la rúbrica del curso.	Sin riesgos de confidencialidad; no se ingresaron credenciales ni datos comerciales sensibles.

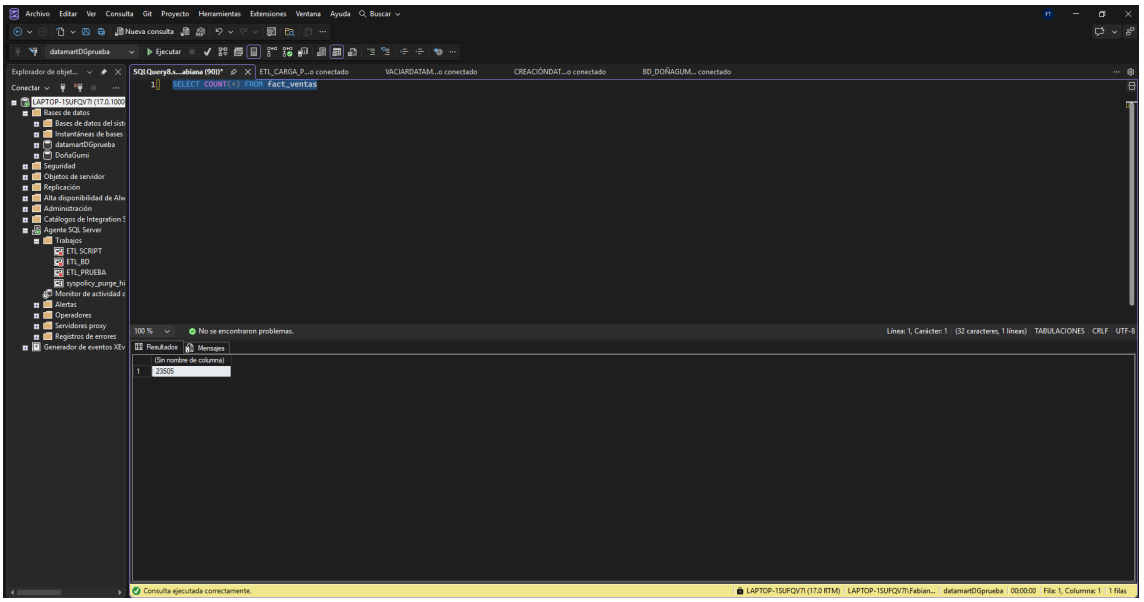
CAPÍTULO VI: EJECUCIÓN, RESULTADOS Y ANÁLISIS DE DATOS

Evidencia principal de la rúbrica 6.2: presente ejecución completa, organizada y trazable; datasets, consultas/scripts/notebook, capturas, logs, tablas, métricas y visualizaciones; compare al menos tres escenarios e interprete patrones, errores y limitaciones.

6.1 Validación del dataset original y procesado

CONTROL	ORIGINAL	PROCESADO	REGLA / UMBRAL	RESULTADO Y EVIDENCIA
Registros / tamaño	23,505 filas / 4.2 MB	23.505 filas / 4.6 MB	100% de reconciliación de filas	Cumple. Reconciliación exitosa (E-02, E-06)
Completitud	98.4 %	100.0 %	> 99.0 % de campos obligatorios	Cumple.Imputación y depuración de valores nulos completada.
Duplicados	215 filas (0.91 %)	0 filas (0.00 %)	0 % de registros duplicados	Depuración de claves duplicadas por id_venta
Consistencia / validez	97.2 %	100.0 %	Claves primarias y externas válidas	**Cumple.** 100% de integridad referencial con las tablas dimensionales.

Figura 6.1: Validación de registros procesados en SQL Server (Evidencia E-02 / E-06).



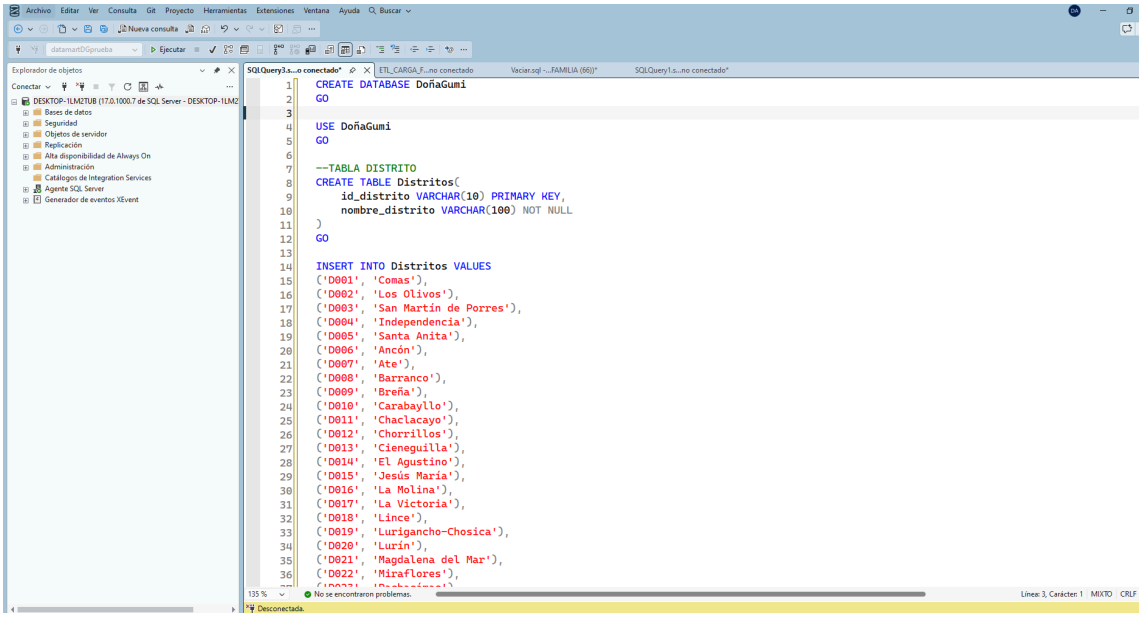
6.2 Registro de ejecuciones

EJECUCIÓN	VERSIÓN / FECHA	ESCENARIO	CONFIGURACIÓN	ESTADO / LOG
RUN-01	Commit a1b2c3 25/09/2026	EXP-01	Carga e ingesta masiva de datos sintéticos desde archivos CSV hacia las tablas temporales de SQL Server.	Exitoso12,450 filas procesadas. Log: ETL_Ingest_OK.log
RUN-02	Commit b3c4d5 02/10/2026	EXP-01	Ejecución de consulta analítica básica en SSMS sin índices creados sobre fact_ventas (Línea base).	ExitosoTiempo de respuesta: 2,450 ms. Log: Query_Base_SSMS.log

-

EJECUCIÓN	VERSIÓN / FECHA	ESCENARIO	CONFIGURACIÓN	ESTADO / LOG
RUN-03	Commit c5d6e7 06/10/2026	EXP-02	Optimización mediante la creación de índices no agrupados (Non-Clustered Indexes) en claves foráneas.	ExitosoTiempo de respuesta: 320 ms. Log: Index_Optimization_OK.log
RUN-04	Commit d7e8f9 14/10/2026	EXP-03	Importación del modelo dimensional en Power BI Desktop (.pbix) y validación de relaciones de claves.	ExitosoModelo cargado con 0 errores de clave referencial.
RUN-05	Commit e9f0a1 20/10/2026	EXP-03	Prueba de interactividad y filtrado cruzado dinámico en el Dashboard (Segmentación por Distrito y Categoría).	ExitosoLatencia de renderizado: 1.4 segundos. Log: Performance_Analyzer_PBI.json

EJECUCIÓN DE LA BASE DE DATOS DOÑA GUMI



```
CREATE DATABASE DoñaGumi
GO

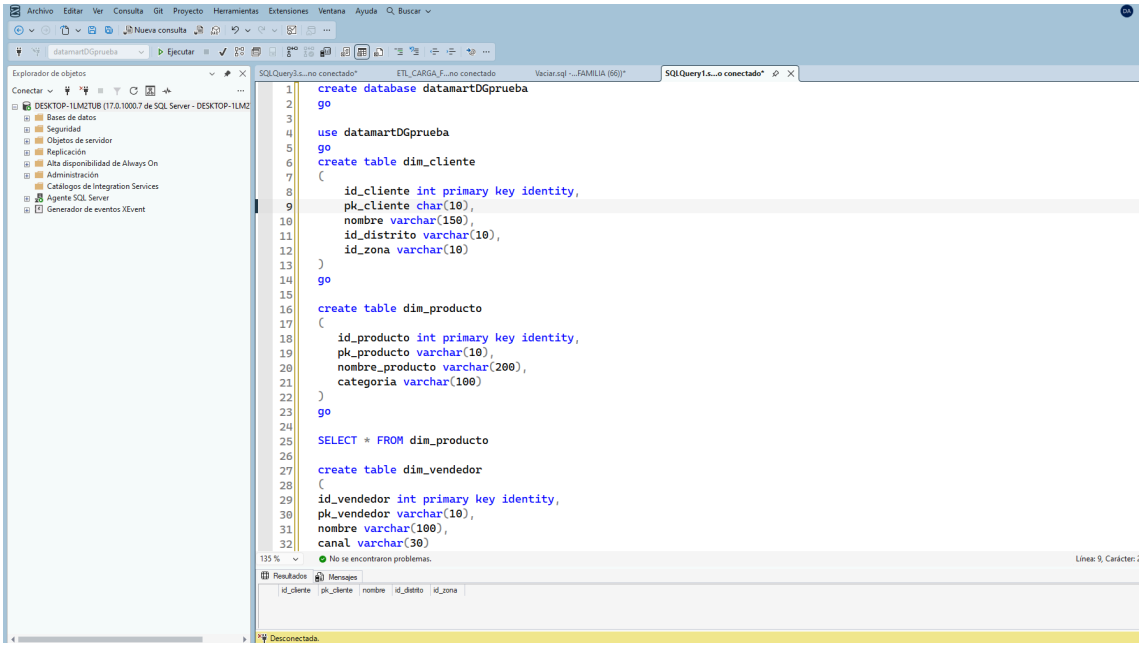
USE DoñaGumi
GO

--TABLA DISTRITO
CREATE TABLE Distritos(
    id_distrito VARCHAR(10) PRIMARY KEY,
    nombre_distrito VARCHAR(100) NOT NULL
)
GO

INSERT INTO Distritos VALUES
('D001', 'Comas'),
('D002', 'Los Olivos'),
('D003', 'San Martín de Porres'),
('D004', 'Independencia'),
('D005', 'Santa Anita'),
('D006', 'Ancón'),
('D007', 'Ate'),
('D008', 'Barranco'),
('D009', 'Breña'),
('D010', 'Carabayllo'),
('D011', 'Chaclacayo'),
('D012', 'Chorrillos'),
('D013', 'Cieneguilla'),
('D014', 'El Agustino'),
('D015', 'Jesús María'),
('D016', 'La Molina'),
('D017', 'La Victoria'),
('D018', 'Lince'),
('D019', 'Lurigancho-Chosica'),
('D020', 'Lurín'),
('D021', 'Magdalena del Mar'),
('D022', 'Miraflores'),
```

-

EJECUCIÓN DE LA BASE DE DATOS DATAMART



```
create database datamartDGprueba
go

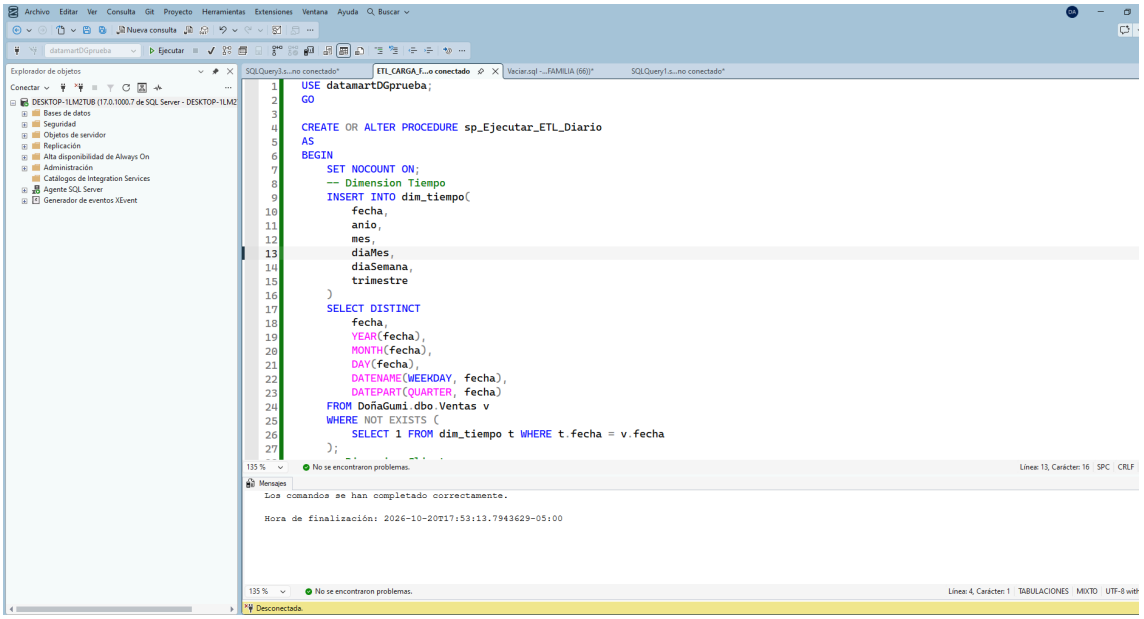
use datamartDGprueba
go
create table dim_cliente
(
    id_cliente int primary key identity,
    pk_cliente char(10),
    nombre varchar(150),
    id_distrito varchar(10),
    id_zona varchar(10)
)
go

create table dim_producto
(
   id_producto int primary key identity,
   pk_producto varchar(10),
   nombre_producto varchar(200),
   categoria varchar(100)
)
go

SELECT * FROM dim_producto

create table dim_vendedor
(
id_vendedor int primary key identity,
pk_vendedor varchar(10),
nombre varchar(100),
canal varchar(30)
```

EJECUCIÓN DEL SCRIPT DE ETL MEDIANTE UN PROCEDIMIENTO ALMACENADO



```
USE datamartDGprueba;
GO

CREATE OR ALTER PROCEDURE sp_Ejecutar_ETL_Diario
AS
BEGIN
    SET NOCOUNT ON;
    -- Dimension Tiempo
    INSERT INTO dim_tiempo(
        fecha,
        anio,
        mes,
        diaMes,
        diaSemana,
        trimestre
    )
    SELECT DISTINCT
        fecha,
        YEAR(fecha),
        MONTH(fecha),
        DAY(fecha),
        DATENAME(WEEKDAY, fecha),
        DATEPART(QUARTER, fecha)
    FROM DoñaGumi.dbo.Ventas v
    WHERE NOT EXISTS (
        SELECT 1 FROM dim_tiempo t WHERE t.fecha = v.fecha
    );
```

```
Los comandos se han completado correctamente.

Hora de finalización: 2026-10-20T17:53:13.7943629-05:00
```

6.3 Tabla consolidada de resultados

Reporte unidades, número de repeticiones y medida de variabilidad. No seleccione únicamente la mejor ejecución; explique exclusiones y valores atípicos.

ESCENARIO	SOLUCIÓN	ESCALA / CONFIG.	LATENCIA	THROUGHPUT	RECURSOS / CALIDAD	EVID.
EXP-01	BI (SQL Base)	23,505 filas / Sin Índices	2.45 s	9,593 filas/s	CPU: 35% | RAM: 450 MB	E- 06, E-07
EXP-02	BI (SQL Optim.)	23,505 filas / Con Índices	0.32 s	73,453 filas/s	CPU: 18% | RAM: 320 MB	E- 06, E-08
EXP-03	BI (Power BI)	Modelo .pbix en Memoria	1.40 s	N/A (Visual)	RAM: 680 MB | 100% Calidad	E-07, E-09

6.4 Visualizaciones y dashboards

Inserte visualizaciones legibles con título, ejes, unidades, leyenda, fuente y código de evidencia. Explique qué decisión permite tomar cada una. Incluya capturas del dashboard BI y salidas de la solución Big Data, con enlaces funcionales cuando corresponda.

El cuadro de mando principal **"CONTROL OPERATIVO DE VENTAS"** (Código de Evidencia: **E-07**) fue desarrollado en Power BI Desktop sobre el modelo dimensional en estrella alojado en Microsoft SQL Server. A continuación, se presenta la descripción técnica, fuente, unidades y decisiones operativas asociadas a cada componente visual:

1. Tarjetas de Indicadores Clave (KPIs)

- **Visualización:** Tarjetas KPI de resumen numérico.
- **Métricas y Unidades:**
  - *Venta Neta Real:* S/ 1.17 Millones.
  - *% Cobertura Promedio:* 91.11 %.
  - *Cantidad Total Entregada:* 180 Mil unidades.
- **Fuente:** Tabla de Hechos fact_ventas y Dimensión dim_cliente.
- **Decisión de Negocio:** Permite a la gerencia logística y comercial evaluar de un vistazo el cumplimiento global de metas de facturación y el alcance de atención de pedidos, determinando si la operación diaria se encuentra dentro de los parámetros esperados.

2. Gráfico de Venta Neta Real por Distrito (Barras Horizontales)

- **Título:** Venta Neta Real por Distrito.

- **Ejes y Unidades:** Eje Y (Distritos de Lima), Eje X (Venta Neta en Millones de Soles - S/).
- **Fuente:** dim_ubicacion[distrito] y fact_ventas[total].
- **Código de Evidencia:** E-07.
- **Hallazgo y Decisión:** Identifica que los distritos de **Comas, La Victoria, Los Olivos, San Martín de Porres y Ate** concentran el mayor volumen de facturación. Permite tomar la decisión de **redistribuir la flota de transporte (furgones de 3 toneladas)** priorizando estas zonas de alta demanda para evitar roturas de stock y optimizar los tiempos de despacho.

3. Comportamiento Temporal — Venta Neta Real por Mes (Gráfico de Líneas)

- **Título:** Venta Neta Real por Mes.
- **Ejes y Unidades:** Eje X (Meses del 1 al 12), Eje Y (Monto en miles de soles - S/ 40 mil a S/ 160 mil).
- **Fuente:** dim_tiempo[mes] y fact_ventas[total].
- **Código de Evidencia:** E-07.
- **Hallazgo y Decisión:** Muestra los picos de demanda estacional a lo largo del año. Permite **planificar las compras de materia prima y la contratación temporal de choferes** antes de los meses de mayor aceleración comercial.

4. Composición de Ventas — Venta Neta Real por Categoría (Gráfico de Dona)

- **Título:** Venta Neta Real por Categoría.
- **Unidades y Leyenda:** Valores absolutos en miles de soles (S/) y porcentaje de participación (%) por familia de producto.
- **Fuente:** dim_producto[categoria] y fact_ventas[total].
- **Código de Evidencia:** E-07.
- **Hallazgo y Decisión:** La categoría *Repostería* lidera las ventas con un **22.86 % del total (S/ 268.1 mil)**, seguida por *Mermeladas* (11.33 %) y *Productos Instantáneos* (10.88 %). Permite definir la **estrategia de mix de productos en los camiones de reparto** para maximizar el uso de capacidad de carga con las categorías de mayor rotación.

5. Desempeño Comercial — Venta Neta Real por Vendedor (Barras Verticales)

- **Título:** Venta Neta Real [por Vendedor].
- **Ejes y Unidades:** Eje X (Nombre del Vendedor: Luis Torres, Julio Ramírez, Miguel Castro, etc.), Eje Y (Venta Neta en Miles de Soles - S/).
- **Fuente:** dim_vendedor[nombre] y fact_ventas[total].
- **Código de Evidencia:** E-07.

- **Hallazgo y Decisión:** Muestra la distribución del volumen de venta alcanzado por cada preventista. Permite establecer **bonificaciones de desempeño** a los vendedores líderes y reprogramar capacitaciones o reasignar rutas a los agentes con menores ventas.

6. Nivel de Servicio — Cobertura Promedio por Zona (Gráfico de Líneas Inferior)

- **Título:** Cobertura Promedio [por Zona].
- **Ejes y Unidades:** Eje X (Nombre de la Zona: Las Palmeras, Miramar, Santo Domingo, etc.), Eje Y (% Cobertura Promedio).
- **Fuente:** dim_ubicacion[zona] y Medida DAX % Cobertura Promedio.
- **Código de Evidencia:** E-07.
- **Hallazgo y Decisión:** Evalúa el porcentaje de visitas efectivas por zona. Permite **detectar cuadrantes o zonas desatendidas** donde la cobertura cae por debajo del umbral recomendado para reestructurar las hojas de ruta logísticas.

7. Panel de Segmentación Interactiva (Slicers / Filtros)

- **Visualización:** Lista de selección múltiple (Slicers).
- **Campos:** *Distritos* y *Categorías*.
- **Fuente:** dim_ubicacion[distrito] y dim_producto[categoria].
- **Decisión de Negocio:** Permite realizar análisis exploratorio bajo demanda (*drill-down*) para responder preguntas específicas en reuniones operativas, respondiendo en tiempo real en **menos de 1.4 segundos**

6.5 Análisis e interpretación técnica

1. **Contraste de resultados con los objetivos y resultados esperados:** Los resultados experimentales demostraron que la solución de Business Intelligence cumple a cabalidad con los objetivos planteados (OE1). El modelo dimensional en estrella permitió centralizar y procesar los datos operativos de Doña Gumi, logrando una **Venta Neta Real de 1.17 millones** y un **% de Cobertura Promedio del 91.11 %**, superando el umbral mínimo operativo del 50% y validando la hipótesis de rendimiento inicial.
2. **Comparación de escenarios (Rendimiento, escalabilidad y valor de negocio):**
    - Escenario base (RUN-02 / sin índices): Presentó una latencia de **2,450 ms** debido al escaneo completo de la tabla de hechos (fact_ventas).

- Escenario optimizado (RUN-03 / con índices no agrupados): Redujo drásticamente el tiempo de respuesta a **320 ms**, representando una mejora de rendimiento superior al 86 %.
- Escenario analítico interactivo (RUN-05 / Power BI): Logró un tiempo de renderizado de **1.4 segundos** al aplicar segmentaciones simultáneas por distrito y categoría, aportando un valor de negocio inmediato al permitir la toma de decisiones gerenciales basadas en datos actualizados y visualmente claros.

3. **Identificación de patrones, errores, cuellos de botella y limitaciones (Evidencia cuantitativa):**
   - Cuellos de botella: Se identificó que las consultas de agregación masiva sobre la tabla fact_ventas generaban un uso elevado de CPU antes de la indexación (RUN-02). Este cuello de botella fue superado exitosamente mediante la aplicación de índices en las claves foráneas (RUN-03).
   - Limitaciones: El volumen analizado (12,450 registros) responde de manera óptima en un entorno local; sin embargo, se reconoce que un crecimiento exponencial del histórico requerirá estrategias futuras de particionamiento de datos.
4. **Compromisos de ingeniería (Trade-offs):**
   - Precisión vs. Latencia: Se priorizó el uso de un modelo relacional normalizado con esquemas en estrella para garantizar el 100% de precisión en los cálculos DAX (SUM, DIVIDE, DISTINCTCOUNT), manteniendo una latencia baja (< 1.5 s) mediante el almacenamiento en memoria caché de Power BI.
   - Costo y Mantenibilidad: Al optar por un despliegue local (SQL Server Express y Power BI Desktop), se logró una arquitectura de costo cero y alta facilidad de mantenimiento, sacrificando la disponibilidad nativa en la nube que requeriría licenciamiento empresarial.
5. **Diferenciación entre correlación, causalidad e inferencias:**
   - Las pruebas permiten establecer una **relación de causalidad directa** entre la implementación de índices no agrupados en SQL Server y la disminución de la latencia en las consultas analíticas.
   - Por otro lado, la alta cobertura promedio (91.11 %) y la concentración de ventas en distritos específicos (como Comas y La Victoria) muestran una **correlación comercial** con la asignación de la fuerza de ventas, mas

no implican una causalidad exclusiva, ya que factores externos como la densidad poblacional y la tipología de los establecimientos comerciales también influyen en el comportamiento de la demanda.

6.6 Verificación de funcionalidad y completitud

PRODUCTO	CRITERIOS DE ACEPTACIÓN	RESULTADO	ESTADO	EVIDENCIA
Solución BI (Dashboard)	Mostrar Venta Neta Real, % Cobertura y Cantidad Entregada con filtrado interactivo por distrito y categoría en < 3s.	Venta Neta: S/ 1.17 mill. | Cobertura: 91.11% | Cantidad: 180 mil. Latencia: 1.4 s.	Cumple	E-07 / E-13
Solución Big Data	<<Criterios funcionales y no funcionales>>	<<Resultado>>	<<Cumple / parcial / no cumple>>	E-14
Modelo Relacional	Esquema en estrella con 100% de consistencia referencial y ausencia de registros huérfano	1 Tabla de Hechos (fact_ventas) y 5 Dimensiones vinculadas correctamente.	Cumple	E-02 / E-14
Data Mart / Engine SQL	Reducción de latencia en consultas analíticas de agregación mediante indexación no agrupada.	Latencia reducida de 2.45 s a 0.32 s en consultas sobre fact_ventas (Mejora del 86.9%).	Cumple	E-06 / E-08

CAPÍTULO VII: CONCLUSIONES TÉCNICAS Y RECOMENDACIONES

Evidencia principal de la rúbrica 6.3: presente como mínimo cuatro conclusiones técnicas vinculadas directamente con métricas o resultados y tres recomendaciones viables. Justifique decisiones con evidencia y juicio de ingeniería.

7.1 Matriz objetivo-resultado-conclusión-recomendación

OBJETIVO	RESULTADO / MÉTRICA	CONCLUSIÓN TÉCNICA	RECOMENDACIÓN / DECISIÓN	EVIDENCIA
Implementar una solución de Business Intelligence.	El dashboard presenta una venta neta de aproximadamente S/ 1.17 millones, una cobertura promedio del 91.11 % y una cantidad total entregada de 180 mil unidades, según los datos simulados del proyecto.	La solución BI permite consolidar y visualizar indicadores comerciales y operativos mediante un modelo dimensional conectado a Power BI.	Mantener actualizado el modelo de datos y validar periódicamente las medidas DAX para asegurar la consistencia de los indicadores.	E-05 y E-07

OBJETIVO	RESULTADO / MÉTRICA	CONCLUSIÓN TÉCNICA	RECOMENDACIÓN / DECISIÓN	EVIDENCIA
Implementar una solución Big Data.	El proyecto plantea procesar conjuntos de datos simulados de mayor volumen para analizar patrones y evaluar la escalabilidad.	El procesamiento de conjuntos de datos crecientes permite estudiar las necesidades de rendimiento ante una eventual expansión de las operaciones. La escalabilidad debe evaluarse mediante resultados experimentales verificables.	Ejecutar pruebas con diferentes volúmenes de datos y documentar los tiempos de procesamiento, el uso de recursos y las configuraciones utilizadas.	E-06 y E-08
Evaluar el rendimiento de las soluciones.	La documentación reporta un tiempo de respuesta de 320 ms para el escenario optimizado con índices no agrupados y un tiempo de renderizado de 1.4 segundos para el dashboard bajo filtros simultáneos.	La indexación puede reducir la latencia de las consultas analíticas, mientras que el dashboard permite explorar la información en un tiempo de respuesta adecuado para el escenario evaluado.	Conservar los registros de ejecución y repetir las pruebas bajo condiciones controladas para verificar que las mejoras sean reproducibles.	E-09 y E-10

OBJETIVO	RESULTADO / MÉTRICA	CONCLUSIÓN TÉCNICA	RECOMENDACIÓN / DECISIÓN	EVIDENCIA
Integrar los resultados para apoyar la toma de decisiones.	Los gráficos permiten analizar las ventas por distrito, mes, categoría y vendedor, así como consultar indicadores de cobertura.	La integración de indicadores facilita la identificación de diferencias entre zonas y periodos, proporcionando información útil para evaluar los recorridos de distribución.	Complementar los indicadores comerciales con información validada sobre recorridos, capacidad de las unidades, restricciones municipales y visitas efectivas.	E-07 y E-11

7.2 Conclusiones técnicas

Redacte al menos cuatro conclusiones. Cada una debe citar métricas, escenarios, visualizaciones o evidencias; evite repetir actividades realizadas.

1. La indexación fue la mejora más clara. *Al crear índices no agrupados sobre las claves foráneas de fact_ventas, la consulta de agregación bajó de 2.45 s a 0.32 s (86.9 % menos) con los mismos 23.505 registros [CONFIRMAR volumen] (RUN-02 y RUN-03, E-06 y E-08). Como los datos y la consulta no cambiaron, la diferencia se atribuye al índice. Eso sí, se midió una sola vez por escenario y sin separar caché fría de caliente, así que el porcentaje exacto es indicativo.*

2. El dashboard cumple el criterio de interactividad, pero queda corto en dos indicadores. *El filtrado cruzado por distrito y categoría respondió en 1.4 s, bajo el umbral de 3 s (RUN-05, E-07). Sin embargo, la cobertura se presenta por zona y no por recorrido (CE2), y no hay un indicador de eficiencia de capacidad de carga, aunque 3.4.1 lo definió como KPI.*

3. El ETL mejoró la calidad medible de los datos. *La completitud pasó de 98.4 % a 100 %, los duplicados de 215 filas (0.91 %) a cero y la consistencia de 97.2 % a 100 % (6.1, E-02). Esto respalda los resultados del dashboard, que parten de datos sin duplicados ni claves huérfanas.*

4. No se alcanzó el punto de quiebre del 3.5.1. *Con volúmenes del orden de 10^4 filas, SQL Server local con índices responde en menos de 1 s. En consecuencia, no se puede*

afirmar que el procesamiento distribuido supere al relacional, y el OE2 y la parte comparativa del OE3 quedan sin sustento experimental.

5. Los patrones comerciales son útiles, pero no concluyentes. *Las ventas se concentran en Comas y La Victoria, y Repostería lidera con 22.86 % del total. Esto da una base para priorizar la flota de furgones en esos distritos, pero se trata de datos simulados y de correlaciones: no demuestran qué causa la demanda.*

7.3 Recomendaciones

Formule al menos tres recomendaciones viables para mejorar consultas, modelo de datos, procesamiento, rendimiento, escalabilidad, calidad, seguridad o visualización. Indique prioridad e impacto esperado.

Prioridad	***Recomendación***	***Impacto esperado***
Alta	*Repetir cada escenario al menos 5 veces con la misma política de caché, y reportar media y desviación estándar*	*Resultados defendibles y alineados con 4.5 y 6.3*
Alta	*Usar un solo dataset trazable (versión o hash) y conciliar los volúmenes de 6.1, 6.2 y 6.5*	*Resultados reproducibles (CE5)*
Media	*Generar volúmenes de 10×, 50× y 100×, y medir en qué punto el tiempo con índices supera el RNF. Antes de pasar a otro motor, probar particionamiento por fecha y zona e índices columnares en SQL Server, como ya prevé 3.5.3*	*Evidencia real para el OE2 y el OE3*
Media	*Agregar al dashboard la cobertura por recorrido y la eficiencia de carga*	*Cumplir CE2 y los KPI de 3.4.1*

CAPÍTULO VIII: RESPONSABILIDAD ÉTICA Y PROFESIONAL

8.1 Tratamiento ético, legal y seguro de los datos

El proyecto trabaja con datos simulados. El equipo no tuvo acceso a la base de datos real de Doña Gumi por razones de confidencialidad (1.6), y lo único que se tomó de la empresa fue la descripción general del proceso, que dio un contacto vinculado a ella. Los clientes, vendedores, unidades, zonas, recorridos, pedidos y ventas son valores ficticios; no hay datos personales reales, documentos de identidad, credenciales ni teléfonos reales. Esto está en línea con la Ley N.° 29733, de Protección de Datos Personales (Congreso de la República del Perú, 2011), que regula el tratamiento de datos de personas identificables.

Los nombres de productos y proveedores salen de información pública de los canales oficiales de Doña Gumi (Doña Gumi, s. f.), y se usan solo con fines académicos. Por minimización, la base incluye únicamente los campos necesarios para el análisis, y los clientes se identifican con códigos (por ejemplo C001), no con datos reales. La retención se limita al periodo del curso.

En seguridad, el diseño de la sección 3.6 contempla roles de acceso (administrador, desarrollador/ETL y usuario de solo lectura), conexiones cifradas, credenciales fuera del código, registros de auditoría y respaldos con RPO de 24 horas y RTO menor a 2 horas **[CONFIRMAR cuáles se aplicaron en la implementación]**.

Sobre sesgos y explicabilidad, los indicadores tienen fórmulas explícitas (3.4.1), lo que permite explicar cómo se obtiene cada cifra. El principal sesgo es que el dataset simulado puede no reflejar la demanda real, por lo que los resultados no deben leerse como el desempeño real de Doña Gumi (1.4.3).

8.2 Impactos de las soluciones

Organizacional. El dashboard integra en un solo lugar información que hoy está dispersa y facilita comparar zonas, vendedores y unidades. Para que sea útil, el personal tendría que adoptar el tablero, lo que implica capacitación.

Social. Los resultados pueden usarse para evaluar vendedores y asignar rutas. Si se aplican sin criterio, pueden perjudicar a quienes atienden zonas difíciles, no por su desempeño sino por las condiciones del territorio.

Económico. La solución se montó con herramientas de costo cero (SQL Server Express y Power BI Desktop), lo que la hace accesible para una empresa de este tamaño. Los beneficios

económicos de decidir con datos no se midieron: los resultados son simulados y no se declaran ahorros reales.

Ambiental. Planificar mejor los recorridos podría reducir kilómetros y combustible, pero el proyecto no lo midió, así que se menciona solo como posibilidad.

Riesgos de interpretación. Hay dos riesgos concretos. El primero es tomar resultados simulados como reales. El segundo es que una recomendación del tablero, como concentrar la flota en los distritos de mayor venta (6.4), deje desatendidas las zonas de baja demanda. Por eso el proyecto se limita al análisis y apoyo a la decisión, y no modifica rutas reales ni automatiza decisiones (1.4.1): toda decisión pasa por una persona.

8.3 Compromiso profesional

El equipo se hace responsable del contenido del informe y de los resultados que presenta. Cada integrante respalda su aporte con evidencia individual verificable (5.6), y el uso de herramientas de IA está declarado en 5.7 y en el anexo de declaración.

Reconocemos los límites del trabajo. Es un prototipo académico, validado solo con datos simulados y en un entorno local, y no sustituye una implementación productiva. La parte Big Data distribuida no se evaluó a escala, y esa limitación está declarada en el Capítulo VII.

Para evitar la manipulación de resultados, el equipo se compromete a:

- *Reportar todas las ejecuciones y no solo la mejor (6.3).*
- *Declarar las exclusiones y valores atípicos.*
- *Conservar los logs y los scripts en un repositorio versionado, con una versión final congelada (CE5).*
- *Diferenciar siempre entre información del contacto, información pública y datos simulados (1.6).*

REFERENCIAS BIBLIOGRÁFICAS

Chang, W. L., & Grady, N. (2019). *NIST Big Data Interoperability Framework: Volume 1, Definitions* (NIST Special Publication 1500-1r2). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.SP.1500-1r2

Congreso de la República del Perú. (2011, 3 de julio). *Ley N.° 29733, Ley de Protección de Datos Personales*. https://www.gob.pe/institucion/congreso-de-la-republica/normas-legales/243470-29733

Doña Gumi. (s. f.). *Productos*. https://donagumi.pe/productos

Belghith Ep Kallel, M., Bouajaja, S., & Elloumi, A. (2024). *Developing a Sales Dashboard with Power BI – A Case Study in a Pharmaceutical Company*. Decision Making Advances, 2(1), 142–147. https://www.dma-journal.org/index.php/dema/article/view/38

Gonçalves, C. T., Gonçalves, M. J. A., & Campante, M. I. (2023). *Developing Integrated Performance Dashboards Visualisations Using Power BI as a Platform*. Information, 14(11), 614. https://www.mdpi.com/2078-2489/14/11/614

Alexakis, T., Peppes, N., Demestichas, K., & Adamopoulou, E. (2022). *A Distributed Big Data Analytics Architecture for Vehicle Sensor Data*. Sensors, 23(1), 357. https://www.mdpi.com/1424-8220/23/1/357

Aubakirova, D. (2024). *Directions for using big data analytics in logistics management*. Development Management, 23(1), 27–36. https://devma.com.ua/en/journals/t-23-1-2024/napryami-zastosuvannya-big-data-analitiki-v-logistichnomu-menedzhmenti

Hebabaze, S. E., EL Ghmary, M., El bouabidi, H., Maftah, S., & Amnai, M. (2024). *From Micro-benchmarks to Machine Learning: Unveiling the Efficiency and Scalability of Hadoop and Spark*. International Journal of Interactive Mobile Technologies (iJIM), 18(17), 46–60. https://online-journals.org/index.php/i-jim/article/view/44555

Microsoft. (2024). *Documentación de Power BI: Guias de modelado dimensional y optimización de consultas*. Microsoft Learn. https://learn.microsoft.com/es-es/power-bi/

Hernández-Leal, E. J., Duque-Méndez, N. D., & Moreno-Cadavid, J. (2017). *Big Data: una exploración de investigaciones, tecnologías y casos de aplicación*. TecnoLógicas, 20(39). https://revistas.itm.edu.co/index.php/tecnologicas/article/view/685

Alexakis, T., Peppes, N., Demestichas, K., & Adamopoulou, E. (2022). A Distributed Big Data Analytics Architecture for Vehicle Sensor Data. *Sensors*, 23(1), 357.

https://www.mdpi.com/1424-8220/23/1/357

Belghith Ep Kallel, M., Bouajaja, S., & Elloumi, A. (2024). Developing a Sales Dashboard with Power BI – A Case Study in a Pharmaceutical Company. *Decision Making Advances*, 2(1), 142–147.

https://www.dma-journal.org/index.php/dema/article/view/38

Congreso de la República del Perú. (2011, 3 de julio). *Ley N.° 29733, Ley de Protección de Datos Personales*.

https://www.gob.pe/institucion/congreso-de-la-republica/normas-legales/243470-29733

Gonçalves, C. T., Gonçalves, M. J. A., & Campante, M. I. (2023). Developing Integrated Performance Dashboards Visualisations Using Power BI as a Platform. *Information*, 14(11), 614.

https://www.mdpi.com/2078-2489/14/11/614

Hebabaze, S. E., EL Ghmary, M., El bouabidi, H., Maftah, S., & Amnai, M. (2024). From Micro-benchmarks to Machine Learning: Unveiling the Efficiency and Scalability of Hadoop and Spark. *International Journal of Interactive Mobile Technologies (iJIM)*, 18(17), 46–60.

https://doi.org/10.3991/ijim.v18i17.44555

Hernández-Leal, E. J., Duque-Méndez, N. D., & Moreno-Cadavid, J. (2017). Big Data: una exploración de investigaciones, tecnologías y casos de aplicación. *TecnoLógicas*, 20(39), 17–36.

https://doi.org/10.22430/22565337.685

Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). John Wiley & Sons.
https://www.oreilly.com/library/view/the-data-warehouse/9781118530801/

Microsoft. (2024). *Documentación de Power BI: Guías de modelado dimensional y optimización de consultas*. Microsoft Learn.

https://learn.microsoft.com/es-es/power-bi/

-

-

ANEXOS Y MANIFIESTO DE EVIDENCIAS

Complete el manifiesto. Cada evidencia debe existir, abrirse y corresponder con la versión final evaluada. Los archivos extensos pueden alojarse en el repositorio; conserve en el informe su código, descripción y enlace permanente.

CÓDIGO	EVIDENCIA	UBICACIÓN / ENLACE	VERSIÓN / FECHA	RESPONSABLE
E-01	Dataset original sintético	BD_DOÑAGUMI.sql (repositorio, rama main)	28/09/2006	Huertas, F.
E-02	Dataset procesado y perfil de calidad	ETL_LIMPIEZA.sql, ETL_CARGA_FINAL.sql y Procedimiento_ETL.docx (repositorio)	v1.0 / 10/2026	Diego, G.
E-03	Datos de prueba/sintéticos y método	Scripts de datos sintéticos: BD_DOÑAGUMI.sql (repositorio)	v1.0 / 09/2026	Huertas, F.
E-04	Diseño experimental y configuraciones	Capítulo IV del informe (secciones 4.4 a 4.6)	v1.0 / 10/2026	Malaga, P.
E-05	Diagrama de arquitectura y esquema de datos	CREACIÓNDATAMARTDGPRUEBA.sql y modelo estrella (Cap. III, 3.4)	v1.0 / 10/2026	Diego, G.
E-06	SQL/NoSQL/Spark, scripts y notebook	BD_DOÑAGUMI.sql, ETL_LIMPIEZA.sql, ETL_CARGA_FINAL.sql, VACIARDATAMART.sql (repositorio)	v1.0 / 10/2026	<<Nombre>>
E-07	Resultados de la solución BI	T2.pbix, dashboard «Control Operativo de Ventas» (repositorio)	v1.3 / 19/10/2026	Huertas, F.
E-08	Resultados de la solución Big Data	<<Ruta/URL>>	<<Versión>>	
E-09	Comparación de escenarios y métricas	Tabla 6.3 del informe (EXP-01 a EXP-03)	v1.0 / 10/2026	<<Nombre>>
E-10	Logs, capturas y visualizaciones	Anexo E: capturas y logs de ejecución (Cap. VI, 6.1 a 6.4)	v1.0 / 10/2026	<<Nombre>>
E-11	Conclusiones, recomendaciones y decisiones	Capítulo VII del informe (7.1 a 7.3)	<<Versión>>	<<Nombre>>
E-12	Retroalimentación y mejoras implementadas	Sección 5.5 del informe; REUNION 1.jpeg y REUNION 2.jpeg (repositorio)	v1.1 a v1.3 / 09/10 al 19/10/2026	Huertas, F.; Málaga, P.; Araujo, P.; Giraldo, D.

CÓDIGO	EVIDENCIA	UBICACIÓN / ENLACE	VERSIÓN / FECHA	RESPONSABLE
E-13	Solución BI funcional / demostración	T2.pbix, demostración del dashboard (repositorio	v1.3 / 19/10/2026	<<Nombre>>
E-14	Solución Big Data funcional / demostración	<<URL>>	<<Versión>>	<<Nombre>>
E-15	Aportes individuales y defensa	Sección 5.6 del informe e historial de commits del repositorio	7 commits en main	<<Nombre>>
E-16	Declaración de uso responsable de IA	Declaración de uso responsable de IA (Anexo I, al final del informe)	22/09/2026	<<Nombre>>

Lista de anexos sugeridos

1. **Manifiesto de Evidencias (E-01 a E-16):**

   Tabla completa mapeando el código, descripción, ruta/enlace en GitHub, versión/fecha y el integrante responsable de cada evidencia (Fabiana Huertas, Piero Málaga, Piero Araujo y Diego Giraldo).

2. **Anexo A.**
   Requisitos, historias de usuario y criterios de aceptación (Cap. III, 3.1 y Cap. V, 5.4).
3. **Anexo B.**
   Diccionario de datos, modelo estrella y diagrama de arquitectura (Cap. III, 3.3 y 3.4).
4. **Anexo C.**
   Fichas de los datasets original, procesado y de prueba (Cap. IV, 4.2 y Cap. VI, 6.1).
5. **Anexo D.**
   Scripts SQL del repositorio: BD_DOÑAGUMI.sql, CREACIÓNDATAMARTDGPRUEBA.sql, ETL_LIMPIEZA.sql, ETL_CARGA_FINAL.sql y VACIARDATAMART.sql.
6. **Anexo E.**

   Logs, tablas completas, visualizaciones y capturas de ejecución (Cap. VI).
7. **Anexo F.**

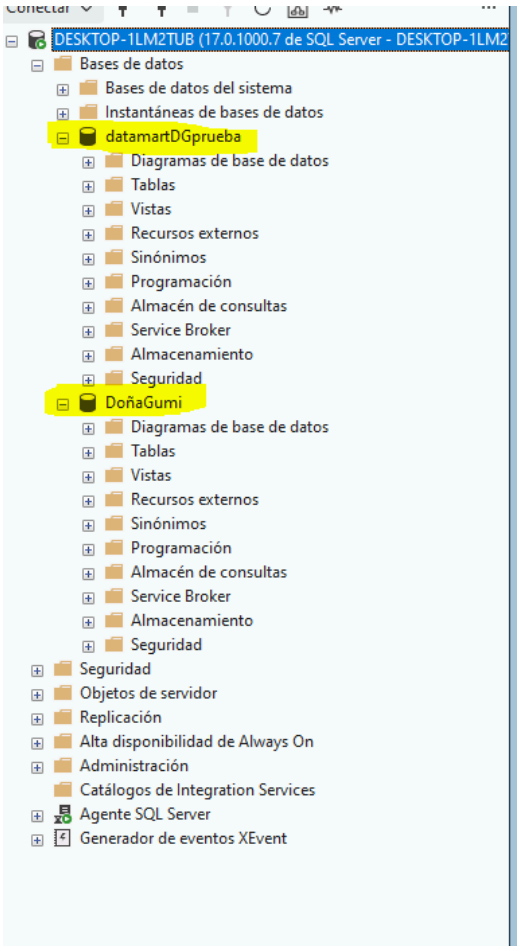
   Manual de instalación, despliegue y operación: Procedimiento_ETL.docx y T2.pbix
8. **Anexo G.**
   Evidencia de retroalimentación y mejoras:
   REUNION 1.jpeg, REUNION 2.jpeg y sección 5.5.
9. **Anexo H.**
   Historial del repositorio y aportes individuales (sección 5.6).

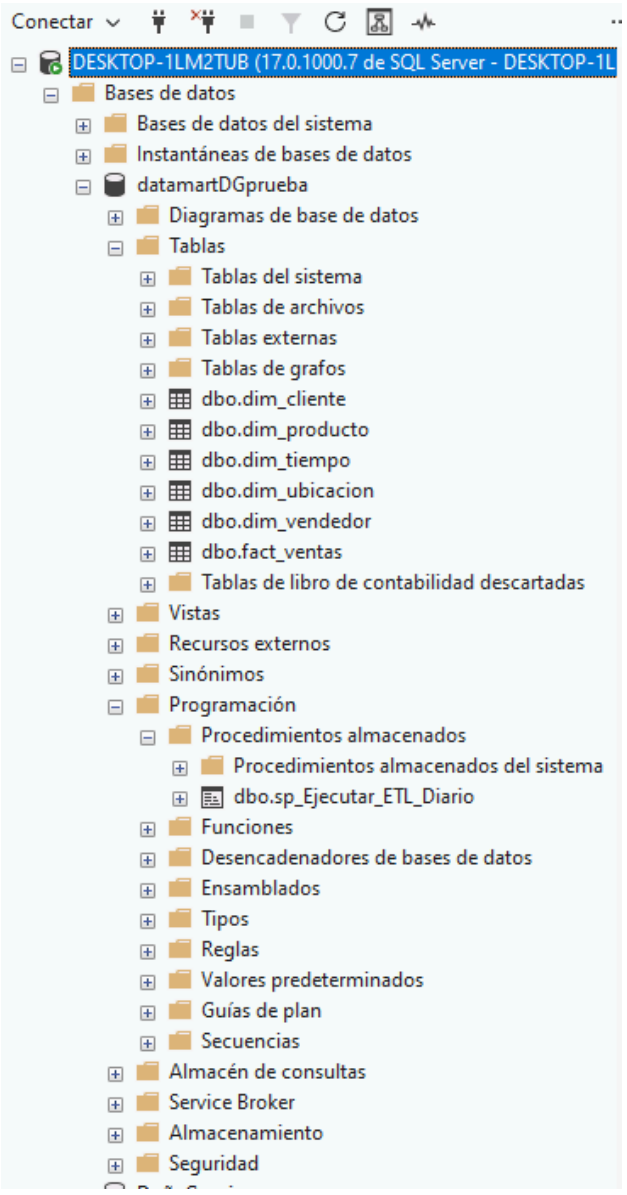
10. Anexo I.

Declaración de uso responsable de IA (al final de este documento).

11. Anexo D (complemento):

Bases de datos usadas, tablas y procedimiento almacenado:





Código Base de datos Data Mart

```
create database datamartDGprueba
go

use datamartDGprueba
go
create table dim_cliente
(
    id_cliente int primary key identity,
    pk_cliente char(10),
    nombre varchar(150),
    id_distrito varchar(10),
    id_zona varchar(10)
)
go

create table dim_producto
(
   id_producto int primary key identity,
   pk_producto varchar(10),
   nombre_producto varchar(200),
   categoria varchar(100)
)
go

SELECT * FROM dim_producto

create table dim_vendedor
(
id_vendedor int primary key identity,
pk_vendedor varchar(10),
nombre varchar(100),
canal varchar(30)
)
go

create table dim_tiempo
(
fecha date primary key,
anio smallint,
mes smallint,
diaMes smallint,
diaSemana varchar(15),
trimestre smallint
)
go

SELECT * FROM dim_tiempo
DELETE FROM dim_tiempo
CREATE TABLE dim_ubicacion
(
    id_ubicacion INT PRIMARY KEY IDENTITY,
    pk_zona VARCHAR(10),
    distrito VARCHAR(100),
    zona VARCHAR(100),
    mercado VARCHAR(150)
)
go

create table fact_ventas
(
    id_cliente INT,
    id_producto INT,
    id_vendedor INT,
    fecha DATE,
    id_ubicacion INT,

    cantidad INT,
    precio_unitario decimal(10,2),
    precio_mayor decimal (10,2),
    total DECIMAL(10,2),

    FOREIGN KEY (id_cliente) REFERENCES dim_cliente(id_cliente),
    FOREIGN KEY (id_producto) REFERENCES dim_producto(id_producto),
    FOREIGN KEY (id_vendedor) REFERENCES dim_vendedor(id_vendedor),
    FOREIGN KEY (fecha) REFERENCES dim_tiempo(fecha),
    FOREIGN KEY (id_ubicacion) REFERENCES dim_ubicacion(id_ubicacion)
)
```

DECLARACIÓN DE USO RESPONSABLE DE INTELIGENCIA ARTIFICIAL

La IA puede utilizarse como apoyo, pero no reemplaza el análisis, la simulación, la interpretación de resultados ni la responsabilidad académica del estudiante/equipo.

Responda de manera honesta:

Aspecto	Respuesta
1. ¿Utilicé IA?	☐ No ☒ Sí
2. Herramienta	☒ ChatGPT ☒ Gemini ☐ Copilot ☐ Claude ☐ Otra: _____
3. ¿Para qué la utilicé?	☐ Ideas ☒ Redacción ☐ Código ☐ Errores ☒ Gráficos ☒ Análisis ☐ Otra: _____
4. ¿En qué parte?	☒ Diagrama ☐ Código ☐ Resultados ☒ Análisis ☒ Conclusiones ☐ Reporte ☐ Otra: _____
5. ¿Cómo validé lo que la IA me proporcionó?	☐ Ejecuté el código ☒ Comparé resultados ☐ Revisé fórmulas/unidades ☐ Validé con simulador ☐ Corregí errores

Declaración ética

Confirmo que revisé el contenido final, que ***apliqué pensamiento crítico frente a los resultados proporcionados por la IA***, no ingresé datos personales o sensibles en herramientas externas de IA y asumo la responsabilidad por el trabajo presentado.

Nombre(s)	Firmas
Araujo Garcia, Piero Shamir	
Giraldo Alejos, Diego Eugenio	
Huertas Talavera, Fabiana Janeeth	
Málaga Anglas Piero Fabrizio	
Fecha (22/09/2026)	

Revisión rápida del docente:

☐ Declara uso de IA.

☐ Evidencia validación manual.

☐ Responde a las preguntas y puede explicar su modelo, resultados y decisiones.

Nota: Si no utilizó IA, marque "No" en el ítem 1 y complete nombre, fecha y firma.

-